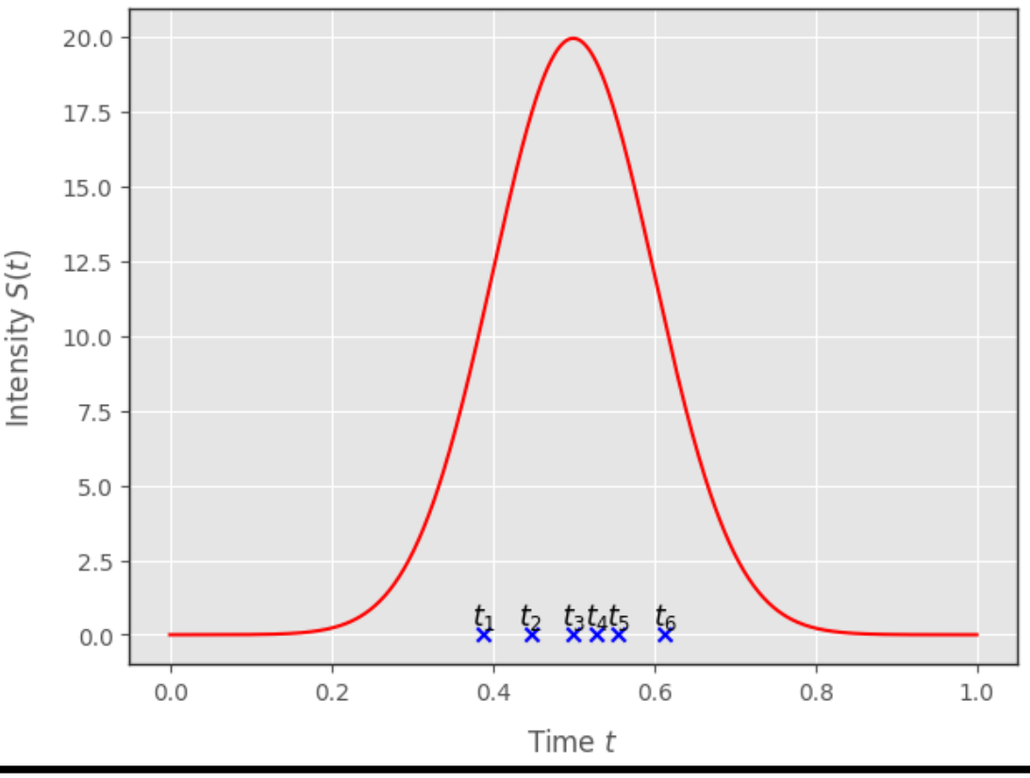
深層学習を用いたポアソン過程データに対するノンパラメトリック回帰

屋良 淳朝[1]，寺田 吉壱[1, 2]

[1]大阪大学 大学院基礎工学研究科，[2] 理研AIP

2025/5/17 応用統計学会2025年年会 @富山国際会議場

研究の全体像



★共変量付きのポアソン過程

$Z \sim P_Z,\ X \mid Z \sim \text{Poisson process}(S(\cdot \mid Z))$

$X \mid Z : \{t_1, \ldots, t_6\}$ ※右図の場合

強度関数 $S(\cdot \mid \cdot)$ の推定が応用上重要

e.g., 救急車需要の強度関数推定 → 出勤台数の最適配置

i.i.d. 観測 $\{(Z_i, X_i)\}_{i=1}^n$ を用いた強度関数 $S(\cdot \mid \cdot)$ の最尤推定量の理論的性質を考察

問題点：汎化誤差 (KL div.) が容易に発散
→ 理論解析が難しい
直接評価するには真の構造に制約が必要

汎化誤差ではなく Hellinger 距離を評価することで解決！

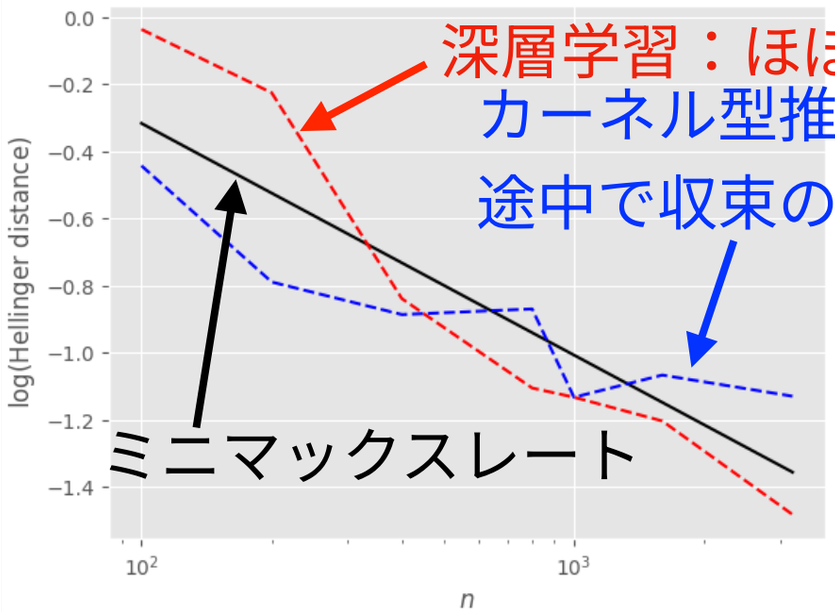
$$\mathrm{KL} \geq \mathrm{Hellinger}^2$$

評価が ✖困難 ◯比較的容易

★**より緩い仮定の下で最尤推定量の性能を評価する不等式を導出 (Theorem 1)**

★**Theorem 1 の重要な応用として，深層学習による強度関数の最尤推定量の収束レートを導出**

★**ミニマックス最適性を証明**



横軸は対数メモリ

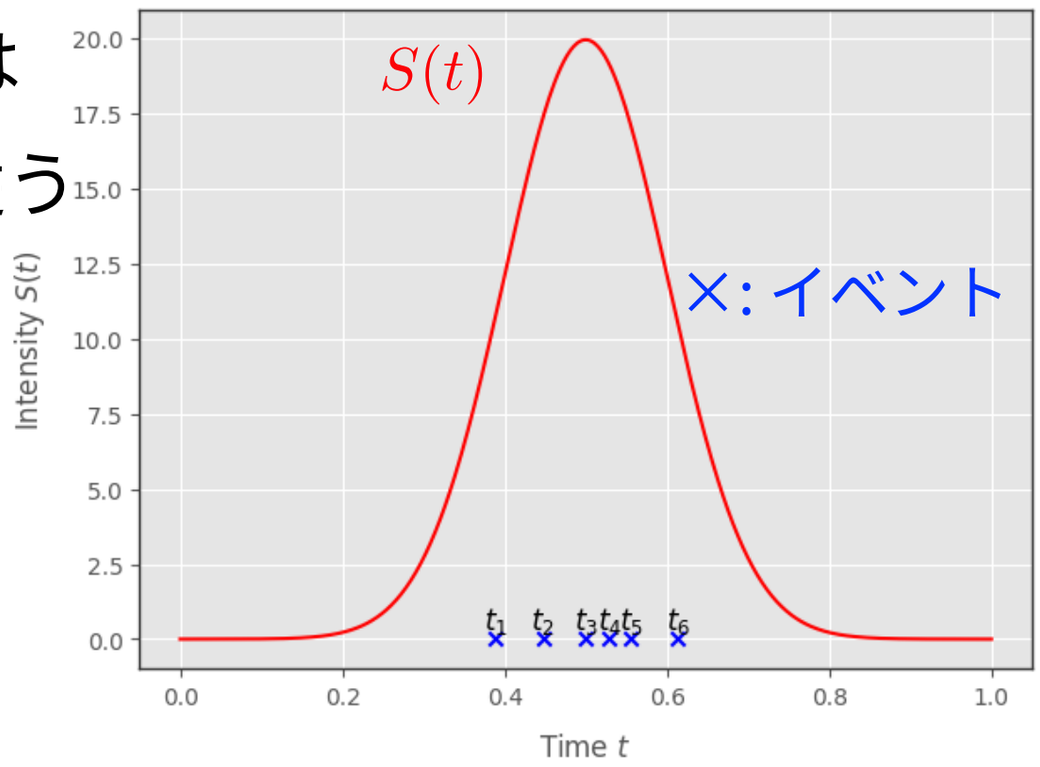
ポアソン過程

☆ポアソン過程と強度関数

- 時空間のランダムな事象の発生を記述する数理モデル
- ポアソン過程 X の定義（簡単のために $[0,1]$ 上のポアソン過程）
  - X は $[0,1]$ 上の非負整数値ランダム測度（点の個数を測る）
  - $X(\{0\}) = 0,\ a.s.$
  - $0 \leq t_1 < \cdots < t_N \leq 1$ に対して，$X([t_1, t_2)), \ldots, X([t_{N-1}, t_N))$ は独立な確率変数
  - $0 \leq s < t \leq 1$ に対して，$X([s,t))$ は強度 $\int_s^t S(\tau)d\tau$ のポアソン分布に従う

強度関数

- 強度関数はその時刻における事象の起こりやすさを表現
- 強度関数が決まればポアソン過程は定まる (informal)



共変量を考慮したポアソン過程

連合大会では共変量なしの場合の結果

⭐条件付き強度関数

- 共変量 Z によって変化する強度関数を考える

$$X \mid Z \sim \text{Poisson process}(S(\cdot \mid Z))$$

条件付き強度関数

- コックス過程の特殊例となっている
  - コックス過程では強度関数がランダム
- 現実のデータでは強度関数も様々な要因で変化するのが自然

応用例 （参考文献）	強度関数	強度関数の変化の要因
山火事の出火点 (D’Angelo et al., 2025)	ある座標における出火の 起こりやすさ	気温・湿度・風速など
事件の発生場所 (Hart et al., 2022)	ある座標における 事件発生率	気温・降水量など

（条件付き）強度関数の最尤推定

⭐条件付き強度関数の最尤推定

- $A \subset \mathbb{R}^{d_1}$: コンパクト集合，$C \subset \mathbb{R}^{d_2}$: 共変量の空間，$d = d_1 + d_2$
- $(Z_1, X_1), \ldots, (Z_n, X_n)$: 共変量と$A$ 上のポアソン過程の i.i.d. 観測

$$Z_i \sim_{\text{i.i.d.}} P_Z, \quad X_i \sim \text{Poisson process}(S_0(\cdot \mid Z_i))$$

- S_0: 真の条件付き強度関数
- 負の対数尤度関数：

$\boldsymbol{x}_{ij}$: X_i に対応する観測点
$N_i = X_i(A)$, ν: A 上の測度

$$\ell_n(X_1, \ldots, X_n, \boldsymbol{z}_1, \ldots, \boldsymbol{z}_n \mid S) \coloneqq \frac{1}{n} \sum_{i=1}^{n} \left\{ -\sum_{j=1}^{N_i} \log(S(\boldsymbol{x}_{ij} \mid \boldsymbol{z}_i)) + \int_A S(\boldsymbol{x} \mid \boldsymbol{z}_i)\, d\nu(\boldsymbol{x}) \right\}$$

- $\mathcal{F}_n$: 仮説空間（推定量の候補の集合）
  - e.g., DNN, カーネル型 (Klutchnikoff & Massiot, 2016)
- ノンパラメトリック最尤推定量 (NPMLE):

$$\hat{S}_n \in \min_{S \in \mathcal{F}_n} \ell_n(S)$$

- 積分項はモンテカルロ近似 or SGD

ノンパラメトリック最尤推定の困難性

☆様々な設定におけるノンパラメトリック最尤推定

- **回帰**
  - 誤差に正規性を過程すると汎化誤差は
    二乗誤差 ⇒ 真の回帰関数が有界であれば二乗誤差も有界
  - 真の回帰関数の有界性は妥当
- **クラス条件付き確率の推定（分類）**
  - 汎化誤差は真の条件付き確率と推定量との
    KLダイバージェンス ⇒ 一般に非有界，容易に発散
  - 評価するためには真の条件付き確率が
    bounded away from zeroであることが必要

$$c < \mathbb{P}(Y = 1 \mid \boldsymbol{x}) < C, \quad 0 < c, C < 1$$

二値分類の場合

- **強度関数の推定**
  - **分類問題と同様に汎化誤差 (KL) が容易に発散**

ノンパラメトリック最尤推定の困難性

- ⭐**条件付き確率の最尤推定におけるKLの発散に対する対処法**
  - 真の条件付き確率に制約 (Ohn & Kim, 2022, Neural Comput.):
    - 📌 真の条件付き確率が bounded away from zero と仮定
      - 👍 汎化誤差の収束レートが導出可能
      - ⚠️ 条件付き確率が極端な値 (0 or 1)をとる場合に対応できない
  - 推定量を改変 (Bilodeau et al., 2023, Ann. Stat.):
    - 📌 推定量を bounded away from zero となるように改変
    - 📌 仮説空間が真の条件付き確率を含むと仮定
      - 👍 汎化誤差の収束レートが導出可能
      - ⚠️ 仮説空間が真の条件付き確率を含まない場合に対応できない
- **評価指標の取り替え ← 本研究**
  - 📌 Bos & Schmidt-Hieber (2022, Electron. J. Stat.):
    打ち切り KL ダイバージェンス
  - 📌 Yara & Terada (2025, Bernoulli): Hellinger 距離
    - 👍 真の構造に仮定が不要

ノンパラメトリック最尤推定の困難性

⭐KLダイバージェンスが発散する例

- ポアソン過程間のKLダイバージェンスには**強度関数の比**が登場

$$\mathrm{KL}(P_f, P_g) = \int_A \left(f \log\left(\frac{f}{g}\right) + g - f \right) d\nu$$

- 推定量のサポートが真の強度関数のサポートを

覆っていなければ発散

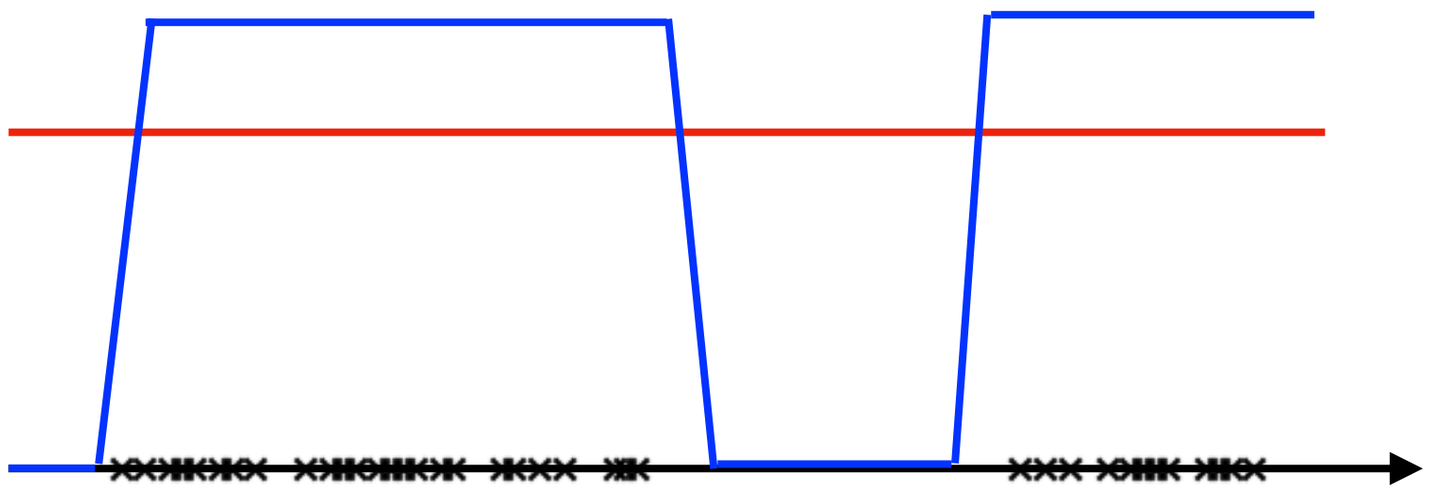
⇒ **汎化誤差の評価が困難**

$P_h : h$ を強度関数として持つ
ポアソン過程の分布

真の強度関数

最尤推定量

✖ 観測データ



本研究の目標

☆共変量を考慮に入れたポアソン過程の強度関数の最尤推定量の理論的性質を明らかにする

- しかし，KLダイバージェンスは容易に発散するため，
  通常の汎化誤差解析の枠組みでは評価が困難
  ⇒ 代わりにHellinger距離を評価
- Bounded away from zeroの条件を緩和して
  速い収束レートを導出 （付録参照）

☆深層学習を用いた最尤推定量

- 深層学習を用いた場合の最尤推定量の性能を評価
  - 真の強度関数が合成関数の構造を持つ場合
    - **次元の呪いを回避 & ミニマックス最適**
  - 真の強度関数が低次元多様体上に台を持つ場合
    - Ward et al. (2023, Biometrika) に比べて，深層学習の場合は
      リーマン計量の推定が不要

記号と仮定

⭐記号

- $\widetilde{H}^2(S_1, S_2) := \mathbb{E}_Z \left[\frac{1}{2} \int_A (S_1(\boldsymbol{x} \mid Z) - S_2(\boldsymbol{x} \mid Z))^2 d\nu(\boldsymbol{x}) \right]$
  - **Poisson過程間のKLダイバージェンスの代わりに この量を評価**
- $\mathcal{F}(L, r, B)$: 深さ L, 各層の幅 r, パラメータの大きさの上界 B の DNN
  - 最終層も含めて全ての活性化関数は $\mathrm{ReLU}(x) = \max(x, 0)$
- $\mathcal{F}(L, r, B, s)$: $\mathcal{F}(L, r, B)$ に加えて，非ゼロのパラメータ数が s 以下

⭐仮定

$$\exists c_0 > 0,\ \forall n \in \mathbb{N},\ \exists S_n^* \in \mathcal{F}_n,\ \forall \boldsymbol{x} \in A,\ \forall \boldsymbol{z} \in C;\ \frac{S_0(\boldsymbol{x} \mid \boldsymbol{z})}{S_n^*(\boldsymbol{x} \mid \boldsymbol{z})} \leq c_0^2$$

- DNNを用いた推定では自動的に満たされる
- 仮説空間のある元が真の強度関数のサポートを覆っている

オラクル不等式

☆オラクル不等式

Theorem 1（オラクル不等式）

ポアソン過程の条件付き強度関数の推定を考える.

δ_n とある普遍定数 c は

$$\sqrt{n}\delta_n^2 \geq c\Psi(\delta_n) \quad (1)$$

を満たすとする．このとき任意の $\delta \geq \delta_n$ に対して

いくつかの仮定の下で, 以下が成り立つ．

Variance

$$\mathbb{E}[\tilde{H}^2(\hat{S}_n, S_0)] \leq 514(c_0+1)^2 \left(\underline{\delta^2} + \frac{c^3}{n} + \underbrace{\tilde{H}^2(S_n^*, S_0)}_{\text{Bias}^2} \right)$$

- Ψ はモデルの複雑さを表す
- モデルの複雑さと Bias の評価ができれば NPMLE の収束レートがわかる！

真の強度関数の構造

★真の強度関数の構造

- 滑らかさ $\boldsymbol{\beta}$, 定義域 D, ノルムの上限 Q のヘルダー空間：$\mathcal{C}^{\beta}(D, Q)$
- ヘルダー空間の元の合成で書ける関数の集合：

$$\mathcal{G}_{\mathrm{comp}}(q, \mathbf{d}, \mathbf{t}, \boldsymbol{\beta}, Q) = \{f = \boldsymbol{g}_q \circ \cdots \circ \boldsymbol{g}_0 : \boldsymbol{g}_i = (g_{ij})_j : [a_i, b_i]^{d_i} \to [a_{i+1}, b_{i+1}]^{d_{i+1}},$$
$$g_{ij} \in \mathcal{C}^{\beta_i}([a_i, b_i]^{t_i}, Q), \text{for some} |a_i|, |b_i| \leq Q\}$$

  - $f(x_1, x_2, x_3) = g_1 \circ \boldsymbol{g}_2(x_1, x_2, x_3) = g_{11}(g_{01}(x_1, x_3), g_{02}(x_1, x_2))$
    - x_1, x_2, x_3：3次元
    - $g_{01}(x_1, x_3)$, $g_{02}(x_1, x_2)$：2次元
  - **背後に低次元構造がある**
- 関数の定義域が低次元多様体：
  - $D = \mathcal{M} \times C$
  - $\mathcal{M} \subset A$ は $d_{\mathcal{M}} < d_1$ 次元のコンパクトなリーマン多様体

深層学習における収束レート

⭐深層学習における収束レート

- Theorem 1 を適用することで，真の関数クラスを固定した下で深層学習における収束レートが導出できる

関数クラス	$\mathcal{C}^{\beta}(\mathcal{M} \times C, \mathcal{Q})$	$\mathcal{G}_{\mathrm{comp}}$
収束レート (データ数の指数部分)	$-\dfrac{\beta}{\beta + d_{\mathcal{M}} + d_2}$	$-\max_{i=0,\ldots,q} \dfrac{\beta_i^*}{\beta_i^* + t_i}$

β_i^*：滑らかさ（付録参照）

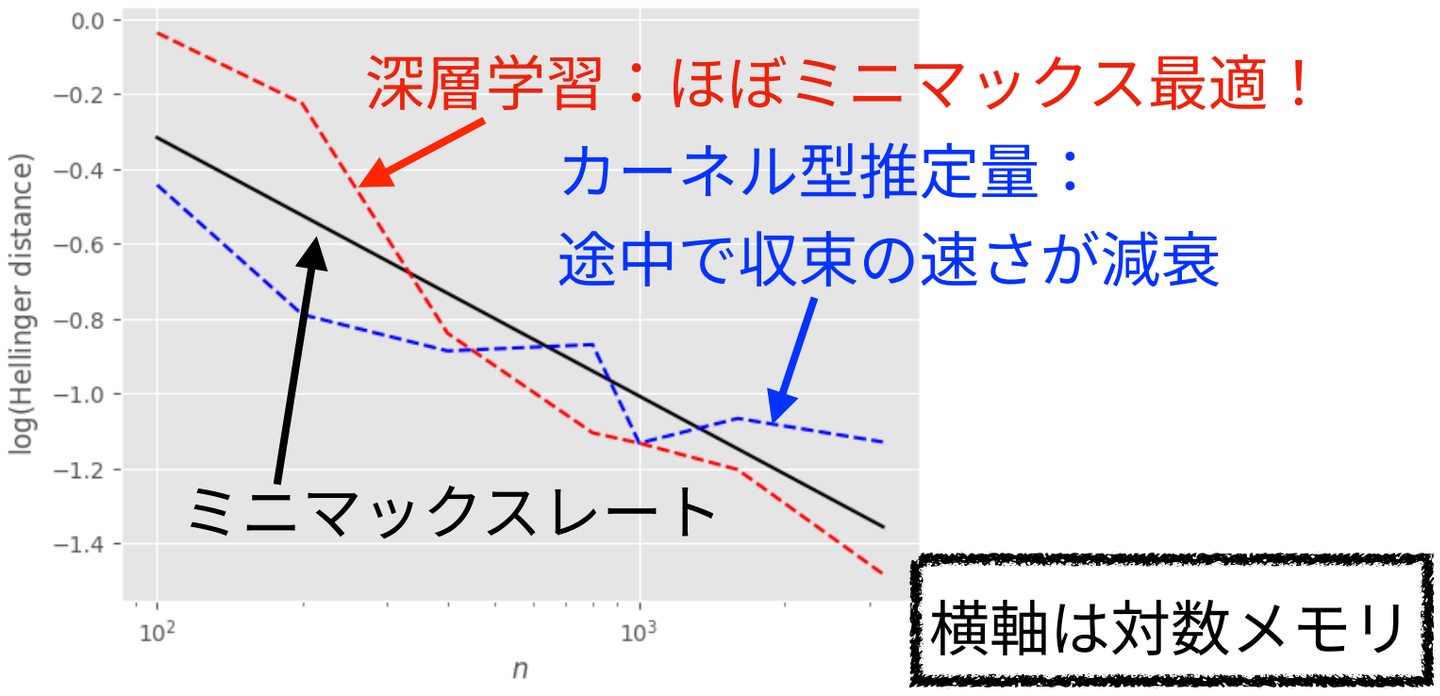
- **深層学習は背後の低次元構造を適切に捉えることができる**
- $\mathcal{G}_{\mathrm{comp}}$ の場合は深層学習における収束レートは

  ミニマックス最適（これ以上改善できない最適な性能を発揮）
- データの背後のポアソン過程の台がリーマン多様体の場合
  - Ward et al. (2023) ではリーマン計量の推定 → 強度関数の推定
  - **深層学習ならデータを入れるだけで適切に推定できる！**

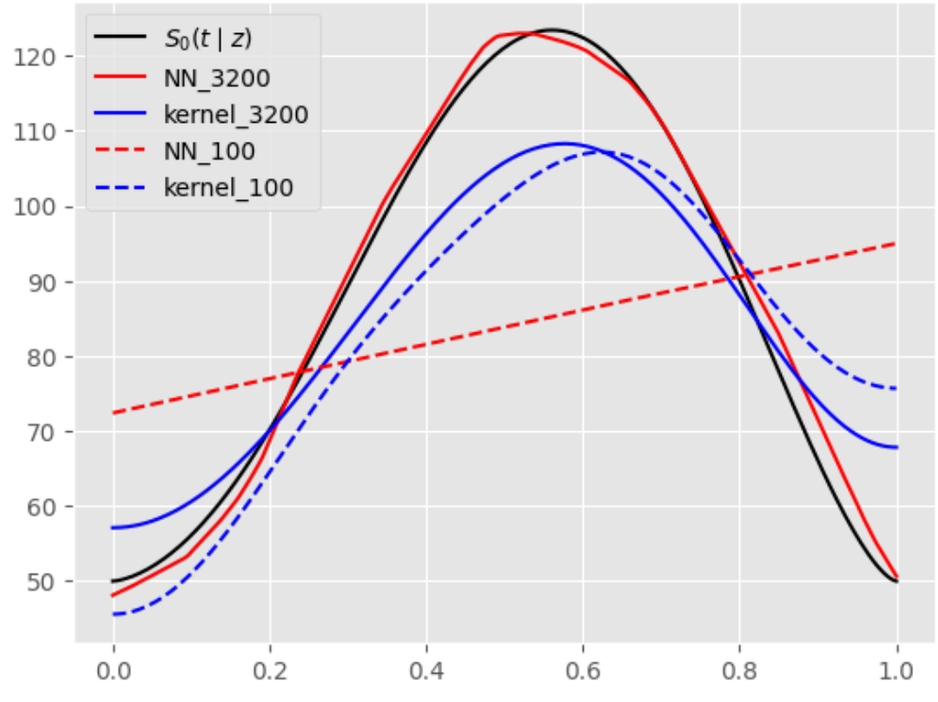
数値実験

⭐真の強度関数が $\mathcal{G}_{\mathrm{comp}}$ の元の場合

- $A = [0,1]$, $C = [0,1]^4$, $d = 5$
- $\boldsymbol{Z} = (Z_1, Z_2, Z_3, Z_4)$, $Z_1, Z_2, Z_3, Z_4 \sim_{\text{i.i.d.}} \mathrm{Unif}(0,1)$
- $S_0(x \mid \boldsymbol{Z}) = 10(5 + Z_1 f(x - Z_2) + Z_3 f(x - Z_4))$
  - $f \in \mathcal{C}^{1.5}([0,1], Q)$
- 前スライドの理論に当てはめると，収束レートは $n^{-3/10}$
  - **これはミニマックスレートでもある**
- 比較手法：カーネル型推定量 (Klutchnikoff & Massiot, 2016)



横軸は対数メモリ



まとめ

- ☆**共変量付きポアソン過程の強度関数に対する最尤推定量の性能を評価する不等式を導出 (Theorem 1)**
- ☆**Theorem 1 を応用し，深層学習を用いた最尤推定量の収束レートを導出した**

関数クラス	$\mathcal{C}^\beta(\mathcal{M} \times C, Q)$	$\mathcal{G}_{\mathrm{comp}}$
収束レート (データ数の指数部分)	$-\dfrac{\beta}{\beta + d_{\mathcal{M}} + d_2}$	$-\max\limits_{i=0,\ldots,q} \dfrac{\beta_i^*}{\beta_i^* + t_i}$

ミニマックス最適

- 合成関数の場合は次元の呪いを回避 & ミニマックス最適
- 多様体上に分布する場合はその多様体の構造を捉える

- ☆**数値実験によって深層学習の優位性を示した**
  - 実験でもほぼミニマックスレートが確認できる

付録

深層学習と次元の呪い

⭐深層学習は次元の呪いを回避できる

- 主に2つのタイプの仮定の下で次元の呪いを回避できることが示されている
  - 真の推定対象の構造に対する仮定
    - mixed-Besov空間 (Suzuki, 2019)
    - 合成関数 (Schmidt-Hieber, 2020) etc…
  - 入力の分布に対する仮定
    - 低次元のリーマン多様体上に分布 (Chen et al., 2019)
    - 低ミンコフスキー次元の集合上に分布 (Nakada & Imaizumi, 2020) etc…
- 収束レートの比較（回帰の場合）

仮定	なし	背後に低次元構造
収束レート (データ数の指数部分)	$-\frac{2\beta}{2\beta+d}$	$-\frac{2\beta}{2\beta+d^*}$

β: 滑らかさ
$d^* \ll d$

Bounded away from zeroの仮定と収束レート

⭐Bounded away from zero → 速い収束レート

- クラス条件付き確率の推定の場合 (Bos & Schmidt-Hieber, 2022)
  - 真の条件付き確率がbounded away from zero
    → 収束レートは $n^{-\frac{2\beta}{2\beta+d}}$ **（ミニマックス最適）**
  - 仮定なしの場合
    → 収束レートは $n^{-\frac{\beta}{\beta+d}}$ **（ミニマックス最適）**
  - α-SVB条件 → 収束レートは $n^{-\frac{(1+\alpha)\beta}{(1+\alpha)\beta+d}}$
- 強度関数の推定の場合
  - 真の強度関数がbounded away from zero (Krichenko & Zanten)
    → 収束レートは $n^{-\frac{2\beta}{2\beta+d}}$ **（ミニマックス最適）**
  - 仮定なしの場合 → 収束レート？
  - α-SVB条件？
    - **条件付き確率の場合と対応する条件も未開拓**

β: 滑らかさ
d: 入力次元

関連研究

⭐カーネル型推定量 (Klutchnikoff & Massito, 2016)

- $A \subset \mathbb{R}$ のような一次元の状況を考える，A の元を t で表す
- 共変量 Z が t に依存することを許す
- 真の強度関数が以下のように書けると仮定
  - $S_0(t \mid Z) = S_0(t \mid \vec{Z}(t))$
  - $\vec{Z}(t)$ は $Z(t)$ のランダムな離散化
- $S_0(t \mid \vec{Z}_i(t))$ たちが全ての i で観測される理想的な状況では，$S_0(t \mid \cdot)$ は Nadaraya-Watson 推定量で回帰できる
- Nadaraya-Watson 推定量に通常の強度関数のカーネル型推定量 (Kutoyants, 1998) をプラグインして推定量を得る
- 安定性のため，Nadaraya-Watson 推定量の分母に小さい値との最大値をとる

関連研究

☆RKHS型推定量 (Flaxman et al., 2017)

- 共変量を考慮しない強度関数の推定
- $k : A \times A \to \mathbb{R}$: 正定値カーネル, $\mathcal{H}_k$: 対応する RKHS
- $S(\boldsymbol{x}) = af(\boldsymbol{x})^2,\ f \in \mathcal{H}_k,\ a > 0$ によって強度関数をモデル化
- 以下の制約付き最尤推定を考える

$$\min_{f \in \mathcal{H}_k} \left\{ -\sum_{i=1}^{N} \log(af(\boldsymbol{x}_i)^2) + a \int_S f(\boldsymbol{x})^2 d\boldsymbol{x} + \gamma \| f \|^2_{\mathcal{H}_k} \right\}$$

- 積分項があるためこのままでは representer theorem が適用できないが，カーネルを適当に変換することで representer theorem を示し，RKHS 推定量を構成した

$$\min_{f \in \mathcal{H}_{\tilde{k}}} \left\{ -\sum_{i=1}^{N} \log(af(\boldsymbol{x}_i)^2) + \gamma \| f \|^2_{\mathcal{H}_{\tilde{k}}} \right\}$$

関連研究との比較

⭐強度関数のノンパラメトリック推定

- Poisson過程の強度関数のパラメトリック推定に関しては，一致性や漸近正規性など，良い性質が成り立つ (Kutoyants, 1998)
- 一方，ノンパラメトリック推定に関する理論研究は少ない
- 特に，推定量がような表現を持たない場合についての理論研究はほとんどない

📌 e.g., 深層学習，決定木

	推定方法	モデル	収束レート	真の強度関数の背後の関数クラス	備考
Flexman et al.	最尤推定	RKHS	-	-	-
Kirichenko & Zanten	ベイズ推定	階層ベイズ	$n^{-\frac{2\beta}{2\beta+d}}$	Hölderクラス	強い仮定 ミニマックス最適
本研究	**最尤推定**	**深層学習**	$n^{-\frac{\beta}{\beta+d}}$	Hölderクラスの要素の合成	**一般的な仮定** **ミニマックス最適**

汎化誤差の下界の評価へ

⭐Basic inequality

Lemma 1 (Basic inequality)

以下が成り立つ.

$$\tilde{H}^2(\hat{S}_n, S_n^*) \leq (\text{Empirical process term}) + (\text{Approximation error})$$

- KLダイバージェンスの評価からHellinger距離の評価に
- この補題を出発点としてHellinger距離の意味での
  推定量の性能を評価する
- van de Geer (2000) の密度推定に関する議論を
  強度関数の推定に対して適応することで得る
  - 密度推定の場合と比べて尤度関数が複雑なので
    経験過程部分がより複雑な形になる

条件付き強度関数に対するα-SVB条件

⭐α-small value bound

- 条件付き強度関数のクラス$\mathcal{H}$がα-SVBであるとは，全ての$S \in \mathcal{H}$に対して以下が成り立つこと

$$\int_C \int_A \mathbb{1}(S(\boldsymbol{x} \mid \boldsymbol{z}) \leq t)\, d\nu(\boldsymbol{x}) dP_Z(\boldsymbol{z}) \leq C t^{\alpha}, \quad \text{for all } t \in (0, \infty)$$

  - $\alpha = 0$で**常に**成り立つ
  - $t = 0$ 付近で成り立てば良い → ゼロ付近での挙動が本質的

- **この条件の下で，近似誤差が改善する**

Theorem 2

真の強度関数がα-SVBであるとき，

$$\|S - S_0\|_\infty \lesssim M^{-1}, \ \inf_{\boldsymbol{z} \in C} \inf_{\boldsymbol{x} \in A} S(\boldsymbol{x} \mid \boldsymbol{z}) \gtrsim M^{-1}$$

を満たす任意の近似関数に対して，

$$\widetilde{H}^2(S, S_0) \lesssim M^{-(1+(\alpha \wedge 1))}.$$

深層学習における収束レート

Theorem 3（深層学習における収束レート）

(1) 真の強度関数が $\mathcal{G}_{\mathrm{comp}}$ に属するとする．サンプルサイズに応じて適当に深さなどを調節したDNN モデルの集合 $\mathcal{F}(L, r, B)$ を考える．

このとき，n に依存しない定数 C が存在して，

$$\mathbb{E}[\widetilde{H}^2(\hat{S}_n, S_0)] \leq C\phi_n \log(n)^3.$$

ここで，$\beta_i^* = \beta_i \prod_{l=i+1}^{r}(\beta_l \wedge 1)$, $\phi_n = \max_{i=0,\ldots,r} n^{-\frac{(1+\alpha)\beta_i^*}{(1+\alpha)\beta_i^* + t_i}}$ である．

(2) 真の強度関数が $\mathcal{C}^{\beta}(\mathcal{M} \times C, Q)$ に属するとする．

サンプルサイズに応じて適当に深さなどを調節したDNNモデルの集合 $\mathcal{F}(L, r, B, s)$ を考える．

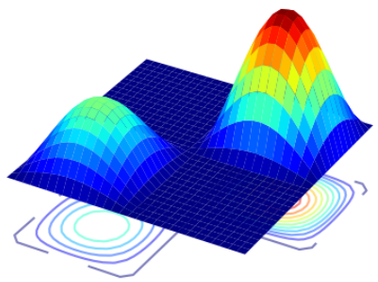
このとき，n に依存しない定数 C' が存在して，

$$\mathbb{E}[\widetilde{H}^2(\hat{S}_n, S_0)] \leq C' n^{-\frac{(1+\alpha)\beta}{(1+\alpha)+d_{\mathcal{M}}+d_2}} \log(n)^3.$$

Composition structured functionの例

⭐タクシーの乗車に関する強度関数の推定

- 大阪市のタクシー乗車頻度を Cox 過程でモデル化するとする
- (x_1, x_2)：大阪市のある一点を表す座標
- $\boldsymbol{z} \in \mathbb{R}^{d-2}$：その他の特徴量（気温, 降水量など）
- $\phi_i(x_1, x_2) = \exp(-((x_1 - \mu_{i1})^2 + (x_2 - \mu_{i2})^2))$：ガウス型の強度
  - i 番目の主要施設周りのタクシーの乗車頻度を表す
- $\phi_{ij}(x_1, x_2, z_j)$：$\boldsymbol{\beta}$ 階微分可能（仮定）
  - j 番目の特徴量が i 番目の建物周りの強度に与える影響を考慮
- 真の強度関数：$S_0(x_1, x_2, \boldsymbol{z}) = \sum_{i,j} \phi_{ij}(x_1, x_2, z_j)$
- このとき, Theorem 2 から収束レートは $n^{-\frac{\beta}{\beta+3}}$



DNNモデルのスパース性

⭐DNN のスパース性について

- 深層学習を用いて汎化誤差解析では, DNN にスパース性を仮定している研究が多い
  - すなわち DNN の非ゼロのパラメータ s は少ないと仮定している
  - e.g. Suzuki (2019), Schmidt-Hieber (2020)
- なぜか？ ⇒ 汎化誤差は, 典型的に以下の形で上から評価できる

$$\frac{\text{“Complexity”}}{n} + \text{Bias}^2$$

- “Complexity”は例えば: covering number, bracketing number
- DNN の covering number の上界は非ゼロのパラメータの数に比例
- ⇒ 非ゼロのパラメータの数 s を制限することで速い収束レートを得る
- **本研究では, よりタイトな Bias の評価 (Kohler & Langer, 2021) を用いることでスパース性を課さずに速い収束レートを示した**

ミニマックス最適性

⭐ミニマックス最適性

- Theorem 2 で導出したレートは何らかの意味で最適か？

Theorem 3（ミニマックス最適性）

Z_j が $[0,1]^{d_2}$ 上の Lebesgue 測度に関する密度をもつ分布に従うとし，その密度が有界であるとする．このとき, 任意の非負整数 r , 任意の $\boldsymbol{\beta} \in \mathbb{R}^r$, 任意の i に対して, $t_i \leq \min(d_0, \ldots, d_{i-1})$ を満たす $\mathbf{d}, \mathbf{t}$ と任意の十分大きい $Q > 0$ に対して, ある正定数 c が存在して

$$\inf_{\hat{f}_n} \sup_{f_0 \in \mathcal{G}_{comp}(q,\mathbf{d},\mathbf{t},\boldsymbol{\beta},Q)} \tilde{H}^2(\hat{f}_n, f_0) \geq c\phi_n$$

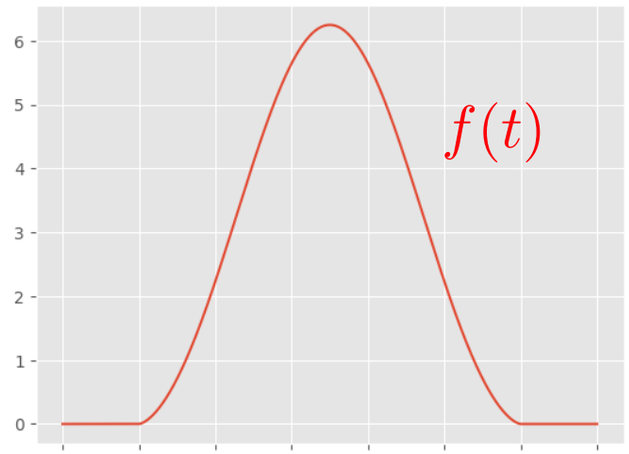
が成り立つ．下限は全ての推定量についてとる．

- Theorem 3 から, Theorem 2 で導出したレートは log-factor を除いてミニマックス最適（これ以上改善できない）

数値実験の詳細

⭐真の強度関数が $\mathcal{G}_{\mathrm{comp}}$ の元の場合

- $A = [0,1]$, $C = [0,1]^4$, $d = 5$
- $\boldsymbol{Z} = (Z_1, Z_2, Z_3, Z_4)$, $Z_1, Z_2, Z_3, Z_4 \sim_{\text{i.i.d.}} \mathrm{Unif}(0,1)$
- $S_0(x \mid \boldsymbol{Z}) = 10(5 + Z_1 f(x - Z_2) + Z_3 f(x - Z_4))$
  - $f \in \mathcal{C}^{1.5}([0,1], Q)$



- 比較手法：カーネル型推定量 (Klutchnikoff & Massiot, 2016)
- DNN は AdamW + early stopping で学習
- カーネル型は 5-fold CV で学習
- どちらも各サンプル数に対して 3回 学習し，中央値を報告
- 学習時間
  - Kernel: 700秒，DNN: 109秒（n = 1000）