深層学習を用いた Poisson 点過程の強度関数の最尤推定

屋良 淳朝[1], 寺田 吉壱[1, 2]

[1]大阪大学大学院 基礎工学研究科, [2] 理研AIP

2024/9/3 2024年度統計関連連合大会 @東京理科大学 神楽坂キャンパス

0. 目次

1. はじめに

1.1. 深層学習

1.2. 深層学習の汎化誤差解析

1.3. Poisson 点過程

1.4. Poisson 点過程の強度関数に対する最尤推定

1.5.ノンパラメトリック最尤推定の困難性

1.6. 本研究の目的

2. 関連研究

2.1. 関連研究

3. 主結果

3.1. 本研究の貢献

3.2. 記号と仮定

3.3. Poisson過程の強度関数のノンパラメトリック最尤推定

3.4. 深層学習を用いた強度関数推定

3.5. まとめ

1. はじめに

1.1 深層学習

▸ 深層学習の発展

- 深層学習は, 現実世界の様々な問題で極めて高い性能を発揮
  - e.g., 画像認識, 自然言語処理
- 深層学習の性能を説明するための理論も盛んに研究されている
- 深層学習の理論研究における主な方向性

- **深層学習の汎化性能に関して**

  ✓**新しいデータに対する性能の良さ**

- 深層学習の近似性能に関して

  ✓どの程度関数を効率よく近似できるか

- 深層学習の最適化に関して

  ✓データにfitするパラメータは最適化で得られるか？

1.3 Poisson点過程

- **Poisson点過程**
  - $(\mathcal{X}, \mathcal{B})$：可測空間
  - λ：$\mathcal{X}$上のσ-有限な測度
  - Intensity measure λのPoisson点過程とは, $\mathcal{X}$上の点過程Xであって以下の2つの性質を満たすもの

1. 全ての$B \in \mathcal{B}$に対して$X(B)$はパラメータ$\lambda(B)$のPoisson分布に従う
2. 全ての$N \in \mathbb{N}$と互いに素な集合$B_1, \ldots, B_N \in \mathcal{B}$に対して, 確率変数$X(B_1), \ldots, X(B_N)$は独立（独立増分性）

  - $\lambda \ll \nu$なるσ-有限な測度に対して, $d\lambda/d\nu(x)$をλのνに関する**強度関数**という
    * 本研究では, ν はLebesgue測度で, λ はLebesgue測度に関して絶対連続であるとする

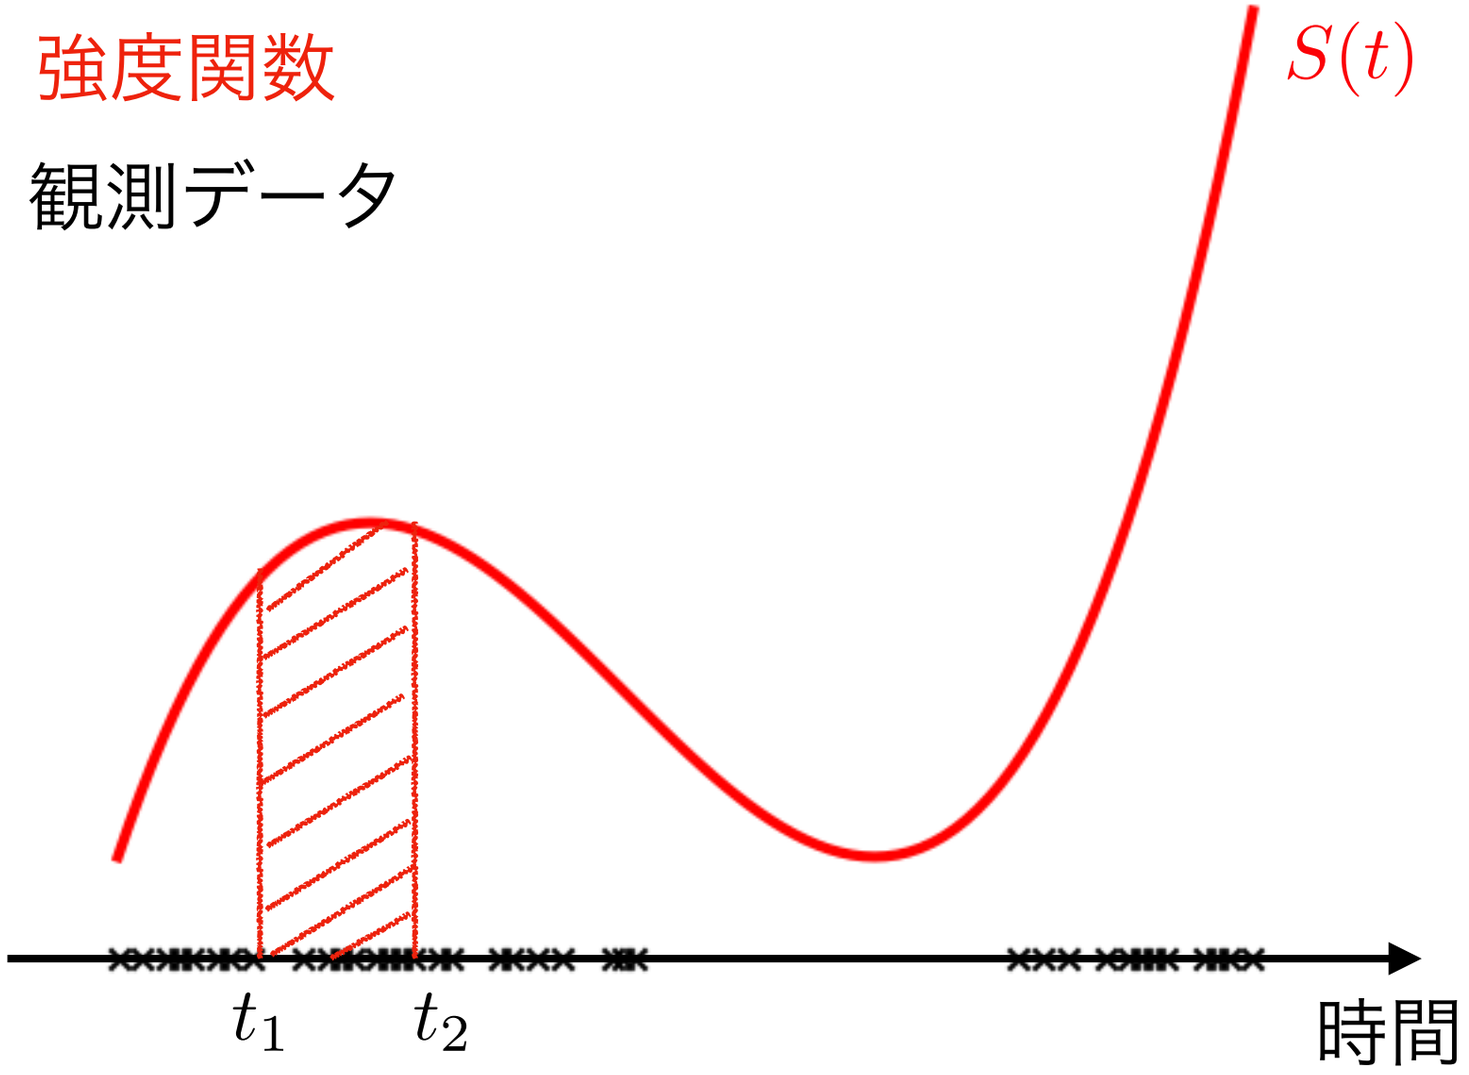
1.3 Poisson点過程

▸ Poisson点過程とは

- 強度関数とPoisson過程の実現値の例

— 強度関数

✖ 観測データ



- $[t_1, t_2]$ での点の個数はパラメータ $\int_{t_1}^{t_2} S(t)dt$ の Poisson 分布に従う

1.4 Poisson 点過程の強度関数に対する最尤推定

- **強度関数の最尤推定**
  - $X_1, \ldots, X_n$：Poisson過程 X からのi.i.d.観測
  - m ：Lebesgue測度, A：コンパクト集合
  - 負の対数尤度関数：

$$\ell_n(X_1, \ldots, X_n \mid S) := -\frac{1}{n}\sum_{i=1}^{n} \ell(X_i \mid S)$$

$$:= -\frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{N_i} \log(S(x_{ij})) + \int_A S(\boldsymbol{x}) m(d\boldsymbol{x})$$

  - ノンパラメトリック最尤推定量 (NPMLE)：$\hat{S}_n \in \min_{S \in \mathcal{F}_n} \ell_n(S)$
  - $\mathcal{F}_n$： モデル（推定量の候補）
  - **本研究では NPMLE の理論的性質について調べる**

1.5 ノンパラメトリック最尤推定の困難性

- **様々な設定におけるノンパラメトリック最尤推定**
  - **回帰**
    - 回帰分析の場合, 誤差に正規分布を仮定すると汎化誤差は

      二乗誤差 ⇒ 真の回帰関数が有界であれば二乗誤差も有界
    - **真の回帰関数の有界性は妥当**
  - **クラス条件付き確率の推定（分類問題）**
    - 分類問題の場合, 汎化誤差は真の条件付き確率と推定量との

      KLダイバージェンス ⇒ 一般に非有界
    - **（二値分類の例）真の条件付き確率が**

$$c < \mathbb{P}(Y = 1) < C, \quad 0 < c, C < 1$$

      を満たすならば二乗誤差に帰着できる ⇒ 非現実的な仮定
  - **強度関数の推定**
    - **汎化誤差は, 真のPoisson過程と推定された強度関数に対応するPoisson過程とのKLダイバージェンス ⇒ 分類と同様に現実的な仮定の下で発散**

1.5 ノンパラメトリック最尤推定の困難性

- **ノンパラメトリック最尤推定の困難性**

Lemma 1

真の強度関数が $S_0(x) = 1\ (\forall x \in [0,1])$ を満たすとする.

また, モデル$\mathcal{F}_n$ が以下を満たす関数を含むとする.

$$\forall x \in [0, 1/3];\ S(x) = 2 \ \text{ and } \ \forall x \in [2/3, 1];\ S(x) = 0.$$

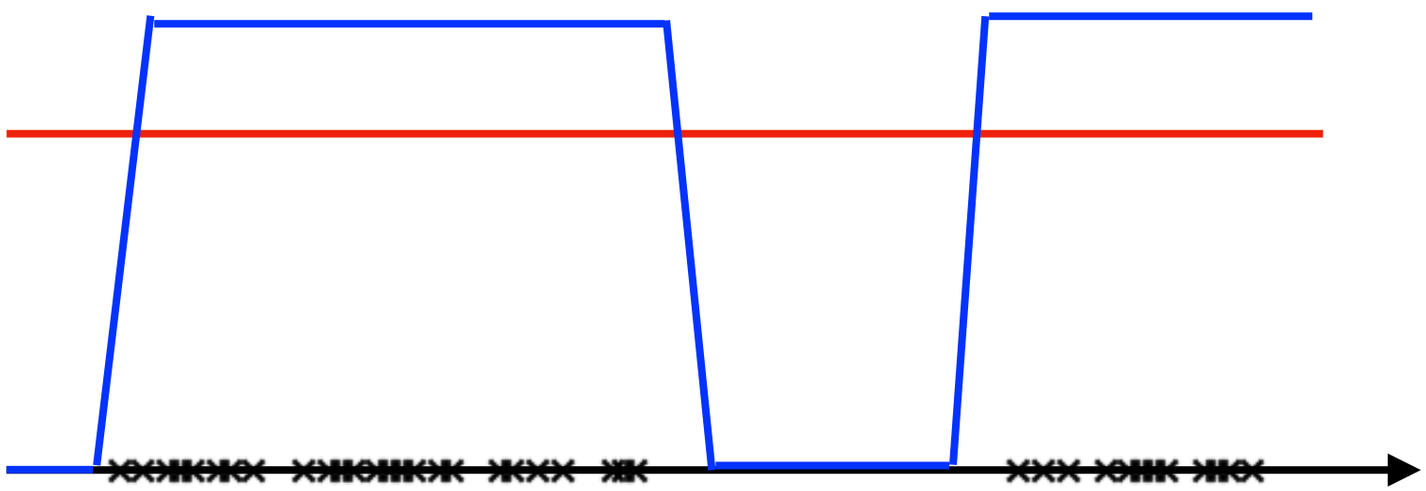
このとき, 期待KL損失が発散する最尤推定量 $\hat{S}_n \in \mathcal{F}_n$ が存在する.

$$\mathbb{E}[KL(S_0 \parallel \hat{S}_n)] = \infty$$

— 真の強度関数

— 最尤推定量

✖ 観測データ



1.5 ノンパラメトリック最尤推定の困難性

▸ ノンパラメトリック最尤推定の困難性

- 最尤推定の場合, 汎化誤差は真のPoisson過程と推定量のKLダイバージェンスとなる
- **しかし, KLは容易に発散することが知られているため評価が困難**

  ⇒ 従来の汎化誤差解析（損失関数の期待値の収束）は難しい

- **van de Geer (2000) の密度推定に関するテクニックを応用してKLの代わりにHellinger距離を評価することによって解決！**
  - Hellinger距離はKLダイバージェンスの下界

    ⇒ 弱い意味での収束を扱う代わりに発散を回避
  - 実は, 尤度の性質が悪いため密度推定よりも難しい

1.6 本研究の目標

▸ 本研究の目標

- Poisson 過程は現実世界において多岐にわたる有用な応用を持つ
  - タクシーの乗車の頻度
  - サッカーにおける得点数
- **現実の問題をPoisson 過程でモデリングするには強度関数が必須**

⇒ 強度関数の推定に深層学習は強力な候補

- しかし, どのような状況で深層学習を用いるべきかは自明ではない

⇒ 理論解析によって強度関数がどのような性質を

持つときに深層学習による最尤推定がうまくいくかを明らかに

⇒ 現実の問題で深層学習を用いる一つの根拠を提供する

2 関連研究

2.1 関連研究

- **関連研究との比較**
  - Poisson 過程の強度関数のパラメトリック推定に関しては, 一致性や漸近正規性など, 良い性質が成り立つ (Kutoyants, 1998)
  - 一方で, **ノンパラメトリック推定に関する理論研究は少ない**
  - 特に, 深層学習や決定木など, 推定量が陽な表現を持たない場合についての理論研究はほとんどない

	推定方法	モデル	収束レート	真の強度関数の背後の関数クラス	備考
Flexman et al.	最尤推定	カーネル法	-	-	-
Kirichenko & Zanten	ベイズ推定	階層ベイズ	$n^{-\frac{2\beta}{2\beta+d}}$	Hölderクラス	強い仮定 ミニマックス最適
本研究	**最尤推定**	**深層学習**	$n^{-\frac{\beta}{\beta+d}}$	Hölderクラスの要素の合成	**一般的な仮定** **ミニマックス最適**

*__Remark:__ 強い仮定 = 「$\exists c,\ S_0 > c$」, これを課せば同じレートが得られる

2.1 関連研究

- **条件付き確率の推定との関係**
  - **条件付き確率のノンパラメトリック最尤推定においても,**
    同様にKLダイバージェンスの発散の問題が生じる
  - 本研究と同様に, van de Geer (2000) のテクニックを応用して
    収束レートを導くことができる (Yara & Terada, 2024; Reivision中)
    * 詳細は議論は強度関数の推定とは異なる
- その他のアプローチもあり, 近年研究が盛んに行われている
  - **打ち切りKLダイバージェンスを評価**
    (Bos & Schmidt-Hieber, 2022; Electric Journal of Statistics)
  - **MLEを少し変換することによって発散を回避**
    (Bilodeau et al., 2023; Annals of Statistics)
- 提案手法のアプローチは, よりシンプルで見通しが良い!

2.1 関連研究

▸ 分類問題におけるノンパラ最尤推定のまとめ

	評価指標	損失関数	備考
Hu et al. (2020, arXiv)	誤判別率	0-1損失 ヒンジロス	強い仮定が必要 **ミニマックス最適**
Kim et al. (2021, Neural Networks)	誤判別率	ヒンジロス ロジスティックロス	強い仮定が必要 **ミニマックス最適**
Ohn & Kim (2022, Neural Computation)	**条件付き確率の推定** KL divergence	ロジスティックロス	強い仮定が必要 正則化有り
Bos & Schmidt-Hieber (2022, Electronic Journal of Statistics)	**条件付き確率の推定** 打ち切りKL divergence	負の対数尤度	一般的な仮定 KL より弱く, Hellinger より強い収束
Yara and Terada (2024, arXiv)	**条件付き確率の推定** **Hellinger 距離**	**負の対数尤度**	**一般的な仮定** **ミニマックス最適**

3. 主結果

3.1 本研究の貢献

☆Poisson 点過程の強度関数のノンパラメトリック推定
において, 理論的性質の議論は少ない
⇒ 本研究ではノンパラメトリック最尤推定における
理論的性質を解明

☆ノンパラメトリック最尤推定において, 汎化誤差の評価は
KLダイバージェンスの発散の問題から困難
⇒ van de Geer (2000) の密度推定のアプローチを応用し解決

☆深層学習を用いた Poisson 点過程の強度関数の最尤推定量の
収束レートを導出

☆導出した収束レートのミニマックス最適性を証明

3.1 本研究の貢献 (technical)

⭐Theorem 1: 一般のPoisson過程の強度関数の最尤推定の分散を評価する不等式を導出

- モデルによらす一般的に成立
- KLの代わりにHellinger距離を用いることで**弱い条件**の下証明
- van de Geer (2000) のテクニックを用いたシンプルな証明

⭐Theorem 2: Theorem 1 を応用して深層学習を用いた強度関数の最尤推定量の収束レートを導出

- 深層学習が次元の呪いを回避することを示唆
- 多くの研究で仮定されているDNNのパラメータのスパース性を排除

⭐Theorem 3: Theorem 2 の収束レートはミニマックス最適

- 深層学習はこれ以上改善できない最適な収束レートを達成

3.2 記号と仮定

- **記号**
  - $H^2(S_1, S_2) := 1/2 \int (\sqrt{S_1(x)} - \sqrt{S_2(x)})^2 dx$:

    2つの強度関数間のHellinger距離の2乗

    - 本研究では, Poisson過程間のKLダイバージェンスの代わりに

      強度関数間のHellinger距離を評価する

    - Hellinger距離はKLダイバージェンスの下界
- **仮定**
  - $\exists c_0 > 0,\ \forall n \in \mathbb{N},\ \exists S_n^* \in \mathcal{F}_n,\ \forall \boldsymbol{x} \in A;\ \dfrac{S_0(\boldsymbol{x})}{S_n^*(\boldsymbol{x})} \leq c_0^2$

    - 本研究で課す唯一の仮定
    - **DNNによる推定であれば自動的に満たされる**

3.3 Poisson過程の強度関数のノンパラメトリック最尤推定

☆オラクル不等式

Theorem 1（オラクル不等式）

Poisson 過程の強度関数の推定を考える. $\hat{S}_n$ をNPMLEとする.

いくつかの仮定の下で, 以下が成り立つ.

Variance

$$\mathbb{E}[H^2(\hat{S}_n, S_0)] \leq 514(c_0+1)^2 \left(\underline{\delta^2} + \underline{\frac{H^2(S_n^*, S_0)}{\text{Bias}^2}} + \frac{c^3}{n} \right)$$

- δ **はモデルの複雑さに対応**

  ⇒ モデルが複雑なほど Varianceは大きくなってしまう

- **一方, モデルが複雑なほど Bias は小さくなる**
- モデルの複雑さとBiasの評価ができれば

  NPMLEの収束レートがわかる！

- Theorem 1は深層学習に限らず一般のNPMLEに対して成立

3.4 深層学習を用いた強度関数推定

- **DNN モデル**

  - $\sigma(x) := \max(0, x)$: ReLU 活性化関数

  - $\boldsymbol{v} = (v_1, \ldots, v_r) \in \mathbb{R}^r$: バイアス

  - $\sigma_{\boldsymbol{v}}(y_1, \ldots, y_r) = (\sigma(y_1 - v_1), \ldots, \sigma(y_r - v_r))$: バイアスと活性化関数

  - L: 層の数, $\boldsymbol{m} = (m_0, \ldots, m_{L+1})$: 各層の幅,

  - $W_j \in \mathbb{R}^{m_{j+1} \times m_j}$: 重み行列, $\boldsymbol{v}_j \in \mathbb{R}^{m_j}$: バイアスベクトル

$$f : \mathbb{R}^{m_0} \to \mathbb{R}^{m_{L+1}},\ \boldsymbol{x} \mapsto f(\boldsymbol{x}) = \sigma W_L \sigma_{\boldsymbol{v}_L} W_{L-1} \sigma_{\boldsymbol{v}_{L-1}} \cdots W_1 \sigma_{\mathbf{v}_1} W_0 \boldsymbol{x} \quad (\star)$$

$$\mathcal{F}(L, \boldsymbol{m}, B) := \left\{ \text{f of the form } (\star) : \max_{j=0,\ldots,L} \|W_j\|_\infty \vee |\boldsymbol{v}_j|_\infty \leq B \right\}$$

  - 層の数や幅などはデータ数に応じて適切にとる

3.4 深層学習を用いた強度関数推定

- **真の強度関数が所属する関数クラスの設定**

  - Smoothness β のHölder 空間：

$$\mathcal{C}^{\beta}(D,Q)=\Bigg\{ f : D \subset \mathbb{R}^m \to \mathbb{R} : \sum_{\boldsymbol{\alpha}:|\boldsymbol{\alpha}|<\beta} \|\partial^{\boldsymbol{\alpha}} f\|_{\infty} + \sum_{\boldsymbol{\alpha}:|\boldsymbol{\alpha}|=\lfloor\beta\rfloor} \sup_{\boldsymbol{x},\boldsymbol{y}\in D,\, \boldsymbol{x}\neq\boldsymbol{y}} \frac{|\partial^{\boldsymbol{\alpha}} f(\boldsymbol{x}) - \partial^{\boldsymbol{\alpha}} f(\boldsymbol{y})|}{|\boldsymbol{x}-\mathbf{y}|_{\infty}^{\beta-\lfloor\beta\rfloor}} \leq Q \Bigg\}$$

  - Hölder 空間の元の合成で書ける関数の集合：

$$\mathcal{G}_{\text{comp}}(r,\mathbf{d},\mathbf{t},\boldsymbol{\beta},Q) = \{ f = \boldsymbol{g}_r \circ \cdots \circ \boldsymbol{g}_0 : \boldsymbol{g}_i = (g_{ij})_j : [a_i,b_i]^{d_i} \to [a_{i+1},b_{i+1}]^{d_{i+1}},$$
$$g_{ij} \in \mathcal{C}^{\beta_i}([a_i,b_i]^{t_i},Q), \text{for some} |a_i|,|b_i| \leq Q \}$$

  - $f(x_1,x_2,x_3) = g_1 \circ \boldsymbol{g}_2(x_1,x_2,x_3) = g_{11}(g_{01}(x_1,x_3), g_{02}(x_1,x_2))$

    3次元　　2次元

  - **背後に低次元構造がある**

3.4 深層学習を用いた強度関数推定

☆深層学習における収束レート

Theorem 2（深層学習における収束レート）

以下の条件を満たす DNN モデルの集合$\mathcal{F}(L, \boldsymbol{m}, B)$ を考える.

$$\text{(i)}\ \ L \asymp \log(n), \quad \text{(ii)}\ \ \sqrt{n\phi_n} \lesssim \min_{i=1,\ldots,L} m_i, \quad \text{(iii)}\ B \asymp 1/\sqrt{\phi_n}.$$

このとき, n に依存しない定数 C が存在して,

$$\mathbb{E}[H^2(\hat{S}_n, S_0)] \leq C\phi_n L \log^2(n)$$

が十分大きい n に対して成り立つ. ここで,

$\beta_i^* = \beta_i \prod_{l=i+1}^{r}(\beta_l \wedge 1)$, $\phi_n = \max_{i=0,\ldots,r} n^{-\frac{\beta_i^*}{\beta_i^* + t_i}}$ である.

- Variance の評価 ⇒ Theorem 1, Bias の評価 ⇒ Kohler & Langer (2021)
- log-factor を無視すると, 収束レートは ϕ_n
- **収束レートは次元 d に依存していない（次元の呪いの回避）**
- 深層学習は背後の低次元構造（合成関数の構造）をうまく捉える

3.4 深層学習を用いた強度関数推定

- **DNN のスパース性について**
  - 深層学習を用いて汎化誤差解析では, DNN にスパース性を仮定している研究が多い
    - すなわち DNN の非ゼロのパラメータ s は少ないと仮定している
    - e.g. Suzuki (2019), Schmidt-Hieber (2020)
  - なぜか？ ⇒ 汎化誤差は, 典型的に以下の形で上から評価できる

$$\frac{\text{“Complexity”}}{n} + \text{Bias}^2$$

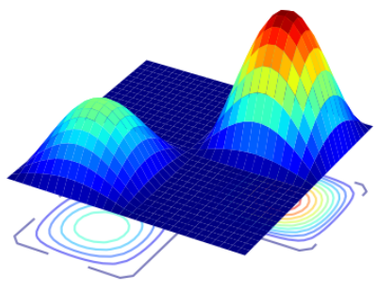
  - “Complexity”は例えば: covering number
  - DNN の covering number の上界は非ゼロのパラメータの数に比例

    ⇒ 非ゼロのパラメータの数 s を制限することで速い収束レートを得る
  - **本研究では, よりタイトな Bias の評価 (Kohler & Langer, 2021) を用いることでスパース性を課さずに速い収束レートを示した**

3.4 深層学習を用いた強度関数推定

- **Theorem 2 の適用例**
  - 大阪市のタクシー乗車頻度を Poisson 過程でモデル化するとする
  - (x_1, x_2)：大阪市のある一点を表す座標
  - $\boldsymbol{y} \in \mathbb{R}^{d-2}$：その他の特徴量（気温, 降水量など）
  - $\phi_i(x_1, x_2) = \exp(-((x_1 - \mu_{i1})^2 + (x_2 - \mu_{i2})^2))$：ガウス型の強度
    - i 番目の主要施設周りのタクシーの乗車頻度を表す
  - $\phi_{ij}(x_1, x_2, y_j)$： $\boldsymbol{\beta}$ 階微分可能（仮定）

    j 番目の特徴量が i 番目の建物周りの強度に与える影響を考慮
  - 真の強度関数：$S_0(x_1, x_2, \boldsymbol{y}) = \sum_{i,j} \phi_{ij}(x_1, x_2, y_j)$
  - このとき, Theorem 2 から収束レートは $n^{-\frac{\beta}{\beta+3}}$



3.4 深層学習を用いた強度関数推定

⭐ミニマックス最適性

- Theorem 2 で導出したレートは何らかの意味で最適か？

Theorem 3（ミニマックス最適性）

X_j が $[0,1]^d$ 上の Lebesgue 測度に関する密度をもつ分布に従うとし，

その密度が有界であるとする．このとき，任意の非負整数 r，

任意の $\boldsymbol{\beta} \in \mathbb{R}^r$，任意の i に対して，$t_i \leq \min(d_0, \ldots, d_{i-1})$ を満たす $\mathbf{d}, \mathbf{t}$

と任意の十分大きい $Q > 0$ に対して，ある正定数 c が存在して

$$\inf_{\hat{f}_n} \sup_{f_0 \in \mathcal{G}_{comp}(q,\mathbf{d},\mathbf{t},\boldsymbol{\beta},Q)} H^2(\hat{f}_n, f_0) \geq c\phi_n$$

が成り立つ．下限は全ての推定量についてとる．

- Theorem 3 から，Theorem 2 で導出したレートは

  log-factor を除いてミニマックス最適（これ以上改善できない）

3.5 まとめ

- まとめ
  - ☆Poisson点過程の強度関数の推定において，分散を評価するための汎用的な不等式を示した (Theorem 2)
  - ☆Theorem 2 の適用例として, 深層学習における強度関数推定の収束レートを導出した (Theorem 3)
  - ☆Theorem 3のレートがミニマックス最適であることを示した

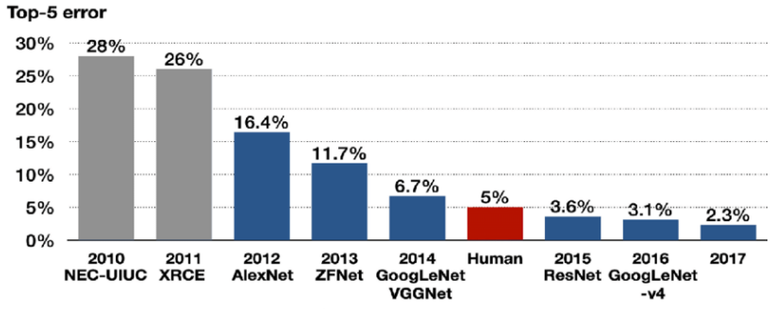
- 今後の展望
  - ☆線形推定量との比較
    - 深層学習が線形推定量を優越することを理論的に示す
  - ☆マーク付き Poisson 過程など, より複雑な点過程への拡張

付録

1.1 深層学習

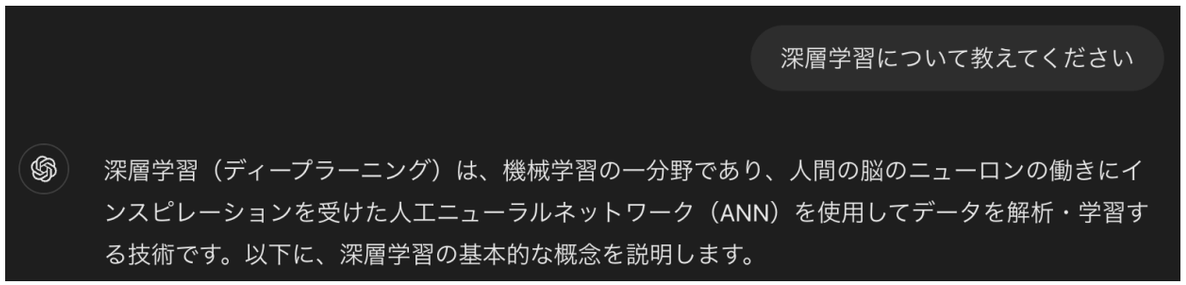
▸ 深層学習の発展

- 深層学習は, 現実世界の様々な問題で極めて高い性能を発揮
  - 画像認識



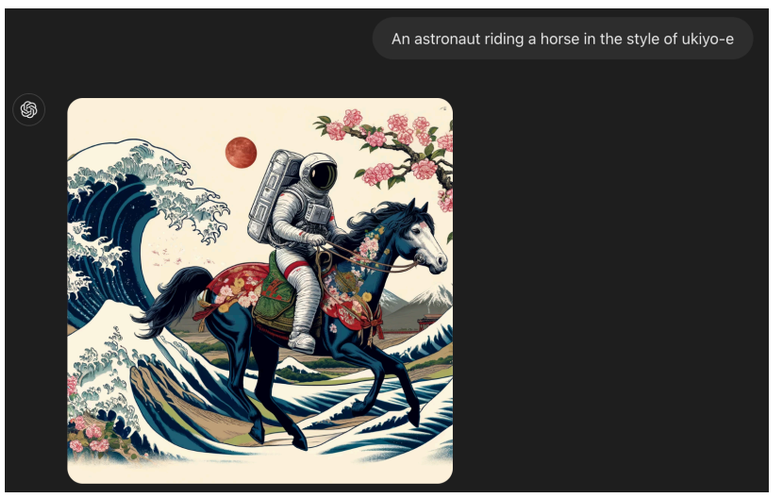
ILSVRCにおける性能の比較.（灰）深層学習以前の手法,（青）深層学習,（赤）人間 , Kang et al. (2020) より

  - 自然言語処理



ChatGPT, OpenAI

  - 画像生成



入力文：”An astronaut riding a horse in the style of ukiyo-e”

1.1 深層学習

▸ 深層学習の発展

- 深層学習の性能を説明するための理論も盛んに研究されている
- 深層学習の理論研究における主な方向性
  - **<u>深層学習の汎化性能に関して</u>**

    ✓<u>新しいデータに対する性能の良さ</u>
  - 深層学習の近似性能に関して

    ✓どの程度関数を効率よく近似できるか
  - 深層学習の最適化に関して

    ✓データにfitするパラメータは最適化で得られるか？

1.1 深層学習

- **理論研究の重要性**
  - 素朴な疑問：

    Q. あらゆる問題は深層学習で解決するのでは？

    ⇒ 実は, 理論的に**否定的な解**が与えられている！

    (**No-free-lunch theorem**, **Slow rates of convergence**)
  - **No-free-lunch theorem の主張 (informal)：**

    どんな学習アルゴリズムにも苦手な問題

    が存在して性能が極端に悪化する
  - **すなわち、全ての問題に対して万能な学習法は存在しない**

    ⇒ 様々な手法の開発と, どういうときに各手法がうまくいく

    か調べることが重要！（理論研究の意義）

1.1 深層学習

- **理論研究の重要性**
  - **“どんな学習アルゴリズムにも苦手な問題が存在して性能が極端に悪化する”**
  - 簡単のため二値分類の例を考える
    - 特徴量 $\boldsymbol{X}$（医療画像）からラベル Y（病気かどうか）を予測
  - “どんな学習アルゴリズムにも”

⇒ 学習アルゴリズム（k-近傍法, 深層学習など）を任意に固定すると

  - “苦手な問題が存在して”

⇒ ある $(\boldsymbol{X}, Y)$ の分布が存在して

    - しかもこの分布は**具体的に構成できる**
  - “性能が極端に悪化する”

⇒ 誤差（誤判別率）の収束を**いくらでも**遅くできる

1.2 深層学習の汎化誤差解析

- **Slow rates of convergence**
  - 例として, 二値分類問題を考える
    - $\mathcal{X} \subset \mathbb{R}^d$：入力空間, $\mathcal{Y} = \{0, 1\}$：出力空間
    - P：$\mathcal{X} \times \mathcal{Y}$ 上の確率分布、$P_{\boldsymbol{X}}$：X の周辺分布
    - $(\boldsymbol{X}, Y), (\boldsymbol{X}_1, Y_1), \ldots, (\boldsymbol{X}_n, Y_n) \sim_{i.i.d.} P$
    - $\mathcal{D}_n := \{(\boldsymbol{X}_i, Y_i)\}_{i=1}^n$：観測データ
  - **目標：新たなデータXが与えられたときに、Yを良く予測するような関数 $\hat{f}_n : \mathcal{X} \to \mathcal{Y}$を$\mathcal{D}_n$から構成する（学習）**
    - $L_n = \mathbb{P}(\hat{f}_n(\boldsymbol{X}) \neq Y \mid \mathcal{D}_n)$：誤判別率（誤った分類をする確率）
    - $L^* = \inf_{f:\text{measurable}} \mathbb{P}(f(\boldsymbol{X}) \neq Y)$：

      最適な分類に対する誤判別率

1.2 深層学習の汎化誤差解析

- **Slow rates of convergence**
  - 観測データ$\mathcal{D}_n$から決定関数 $\hat{f}_n$を得るアルゴリズムを学習法と呼ぶ

Theorem 0 (Slow rates of convergence, Devroye, 1982)

(a_n)をゼロに収束する正数列で, $1/16 \geq a_1 \geq a_2 \geq \ldots$を満たすとする.

任意の学習法に対して, $L^* = 0$を満たすある(X, Y)の分布が存在して,

$$\forall n \in \mathbb{N};\ \mathbb{E}[L_n] \geq a_n$$

が成り立つ.

- **「どんな学習法に対しても"苦手な"問題（分布）が存在して性能が悪化する」と言っている**
- **すなわち, 全ての問題に対して万能な学習法は存在しない**

⇒ 様々な手法の開発と, どういうときに各手法がうまくいくか調べることが重要！（統計的学習理論）

1.2 深層学習の汎化誤差解析

- **統計的学習理論の枠組み**
  - 統計的学習理論の目標：機械学習の手法の**正当性**を与える
  - 正当性の評価 = 汎化誤差の評価
    - 汎化誤差：新しいデータに対する推定量の性能の悪さ
    - 汎化誤差が小さい ⇒ ″良い″推定量
  - 汎化誤差評価の観点
    - 訓練データが増えると汎化誤差はゼロに収束するか？
    - 収束するとしたらその速さ（収束レート）は？
    - 得られた収束レートの″最適性″

1.2 深層学習の汎化誤差解析

- **経験誤差最小化（Empirical Risk Minimization, ERM）**
  - 簡単のために教師あり学習の設定で考える
    - $\mathcal{X}$：入力空間, $\mathcal{Y}$：出力空間, P：$\mathcal{X} \times \mathcal{Y}$ 上の確率分布
    - $(\boldsymbol{X}, Y), (\boldsymbol{X}_1, Y_1), \ldots, (\boldsymbol{X}_n, Y_n) \sim_{i.i.d.} P$
    - $\mathcal{D}_n := \{(\boldsymbol{X}_i, Y_i)\}_{i=1}^n$：観測データ
    - $\ell(\cdot, \cdot) : \mathcal{Y} \times \mathbb{R} \to \mathbb{R}_+$：損失関数
      - どのような問題を考えるかに対応
      - 回帰なら二乗誤差, 分類ならヒンジロスなど
  - 目標：新たなデータ$\boldsymbol{X}$が与えられたときに、Yを**良く予測**する関数 $\hat{f}_n : \mathcal{X} \to \mathbb{R}$を$\mathcal{D}_n$から構成する
  - **「良く予測する」とは？ ⇒ 汎化誤差が小さいこと！**

1.2 深層学習の汎化誤差解析

- **経験誤差最小化（Empirical Risk Minimization, ERM）**
  - 「良く予測する」とは？ ⇒ 汎化誤差が小さいこと!
  - 汎化誤差（超過リスク）：

$$\mathbb{E}_{(X,Y)}[\ell(Y, \hat{f}(X))] - \inf_{f:\text{measurable}} \mathbb{E}_{(X,Y)}[\ell(Y, f(X))]$$

  - 新しいデータに対する損失の期待値は未知 ⇒ **ERM**

- ERM：観測データ$\mathcal{D}_n$上で損失を最小化
  - 推定量 $\hat{f}$ は仮説空間（モデル）$\mathcal{F}$ から探す
  - 本研究では $\mathcal{F}$ は Deep Neural Networks (DNNs)

$$\hat{f} \in \arg\min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^{n} \ell(Y_i, f(X_i))$$

*ERMの解 $\hat{f}$ もしばしばERM (Empirical Risk Minimizer)と呼ぶ

1.2 深層学習の汎化誤差解析

- **汎化誤差のBias-Variance分解**
  - $L(f) = \mathbb{E}_{(X,Y)}[\ell(Y, f(X))]$：期待リスク

$$
\begin{aligned}
& L(\hat{f}) - \inf_{f:\text{measurable}} L(f) \\
&= \underbrace{L(\hat{f}) - \inf_{f \in \mathcal{F}} L(f)}_{\text{Variance}} + \underbrace{\inf_{f \in \mathcal{F}} L(f) - \inf_{f:\text{measurable}} L(f)}_{\text{Bias}}
\end{aligned}
$$

$\mathcal{G}$：可測関数全体

$\mathcal{F}$：仮説空間（モデル）

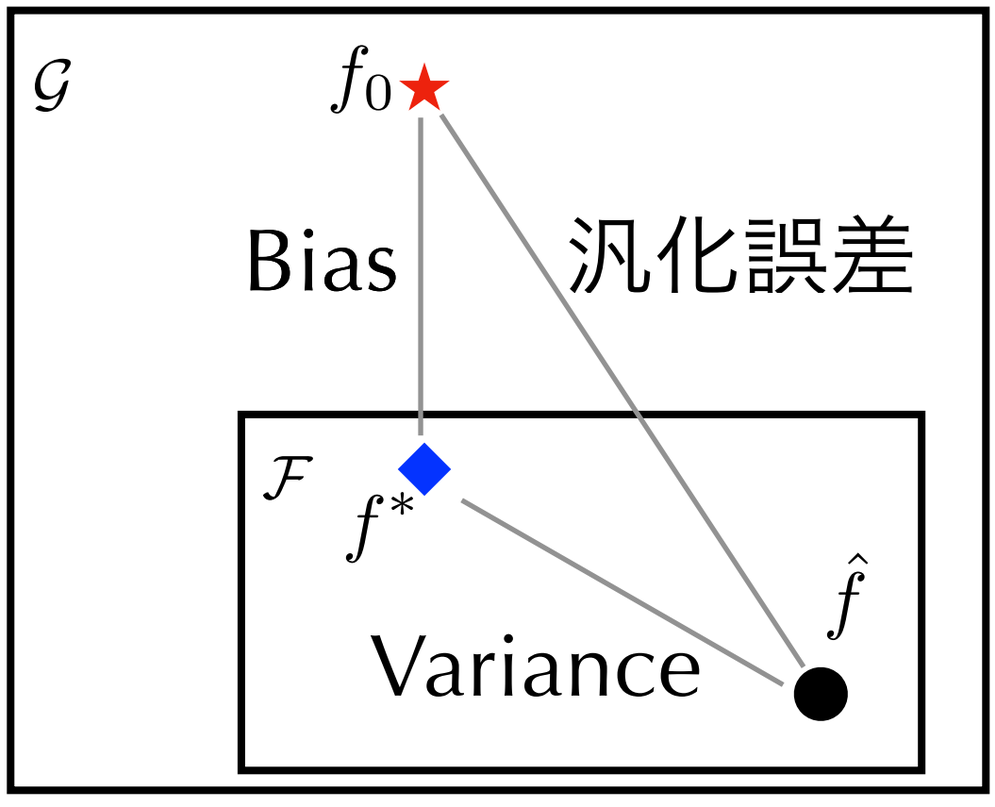
★ $f_0 = \min_{f \in \mathcal{G}} L(f)$

◆ $f^* = \min_{f \in \mathcal{F}} L(f)$

BiasとVarianceは

トレードオフの関係

（モデル$\mathcal{F}$の"大きさ"に依存）

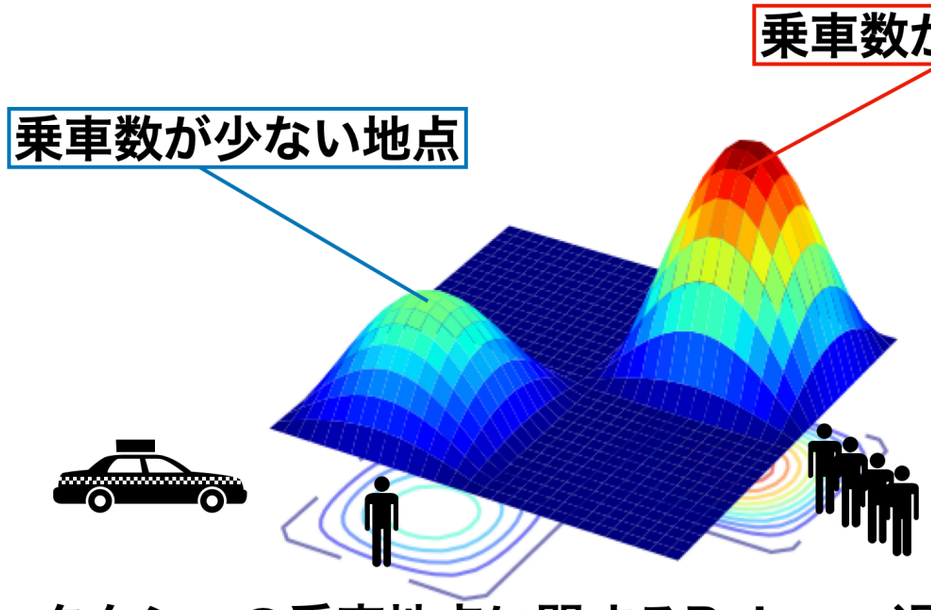


1.3 Poisson点過程

- **点過程**
  - $(\Omega, \mathcal{F}, \mathbb{P})$：確率空間, $(\mathcal{X}, \mathcal{B})$：可測空間
  - $\mathcal{M}_{<\infty} = \mathcal{M}_{<\infty}(\mathcal{X})$：任意の$B \in \mathcal{B}$に対して$\mu(B) < \infty$を満たす$\mathcal{X}$上の非負整数値測度全体からなる空間
  - $\mathcal{M} = \mathcal{M}(\mathcal{X})$：$\mathcal{M}_{<\infty}$に属する測度の可算和で書ける測度全体
  - $\mathcal{N} = \mathcal{N}(\mathcal{X})$：任意の$\mu \in \mathcal{M}$と$B \in \mathcal{B}$に対して$\mu \mapsto \mu(B)$が可測となるような$\mathcal{M}$上の最小の$\sigma$-加法族
  - $(\mathcal{M}, \mathcal{N})$のrandom elementを$\mathcal{X}$上の**点過程**という
  - すなわち, $\mathcal{X}$上の点過程とは可測写像$X : \Omega \to \mathcal{M}$である

1.3 Poisson点過程

- **Poisson点過程とは**
  - 時空間のランダムな事象の発生を記述するモデル
  - 平均的な事象の発生率を記述する**強度関数**で特徴付けられる
  - ある地域におけるタクシーの乗車数を Poisson 過程でモデル化すると, 強度関数はどのエリアで乗車頻度が高いかを表す



タクシーの乗車地点に関するPoisson過程の例
図中の山 (強度関数の値) が高いほど乗車の頻度が高い

タクシーの乗車における Poisson 過程の例



道に落ちたガムの例*

Poisson 過程の直感的説明

- 強度関数：λ（定数）
- 一つのタイルの面積：S

一つのタイルに落ちているガムの数はパラメータ$S\lambda$の Poisson 分布に従う

*https://en.wikipedia.org/wiki/Poisson_distribution

1.4 Poisson 点過程の強度関数に対する最尤推定

- **最適化に関して**
  - 負の対数尤度関数：

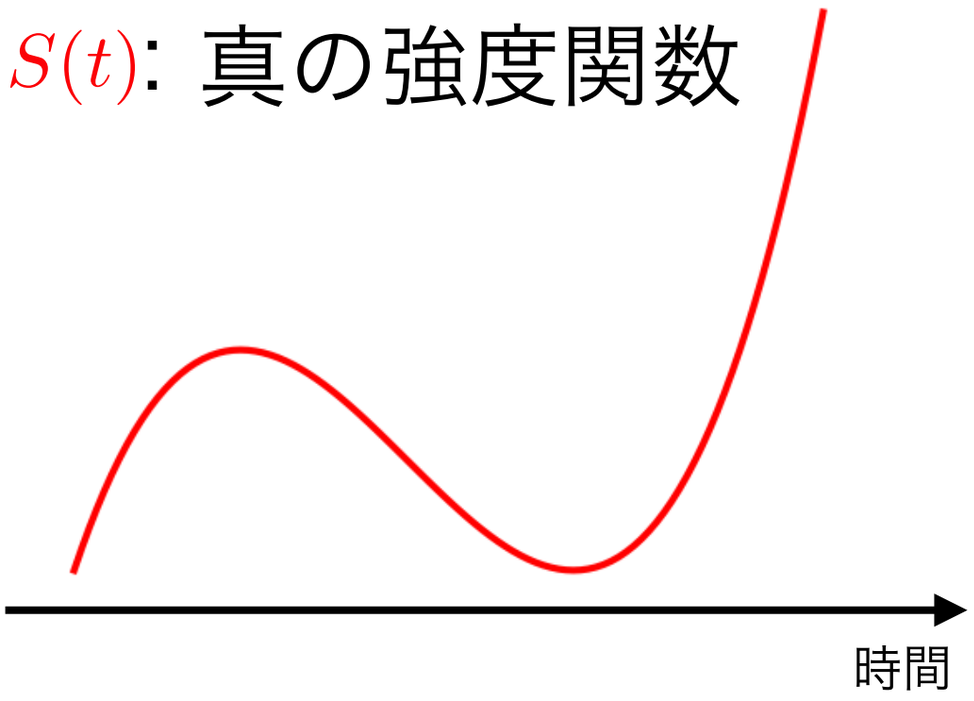
$$\ell_n(X_1, \ldots, X_n \mid S) \coloneqq -\frac{1}{n}\sum_{i=1}^{n} \ell(X_i \mid S) = -\frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{N_i} \log(S(x_{ij})) + \int_A S(\boldsymbol{x}) m(d\boldsymbol{x})$$

  - 最尤推定量：$\hat{S}_n \in \underset{S \in \mathcal{F}_n}{\min}\ \ell_n(S)$

  - Poisson 点過程の負の対数尤度関数は積分を含む
  - 積分は一様分布からのサンプリングに基づくモンテカルロ近似
  - 本研究では，最尤推定量が得られた下でその性質の解析を行う

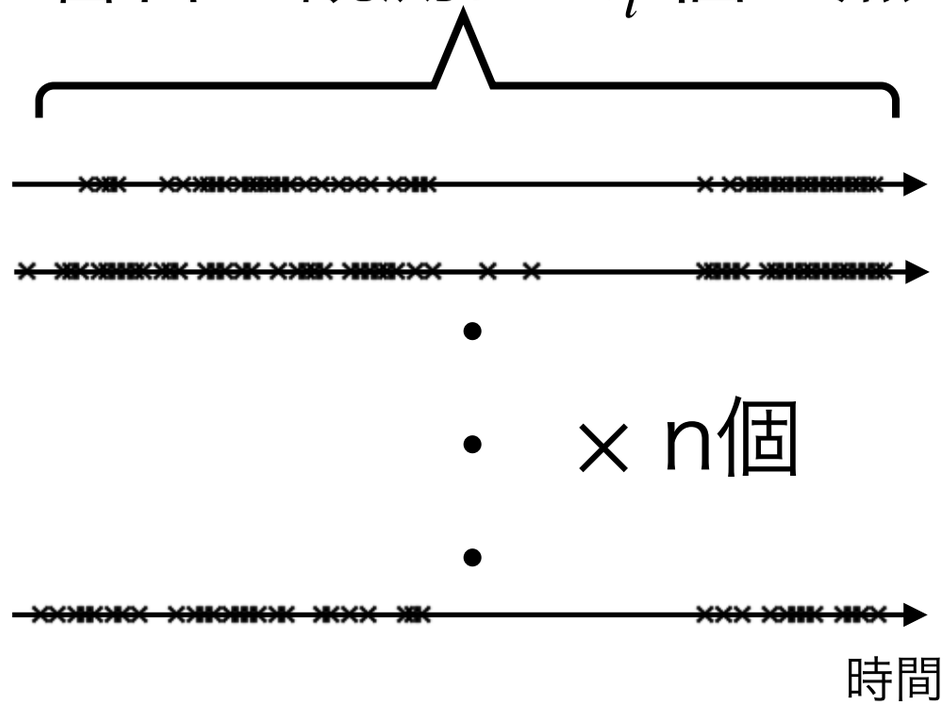
データの発生プロセス

$S(t)$: 真の強度関数



観測

i 番目の観測に N_i 個の点



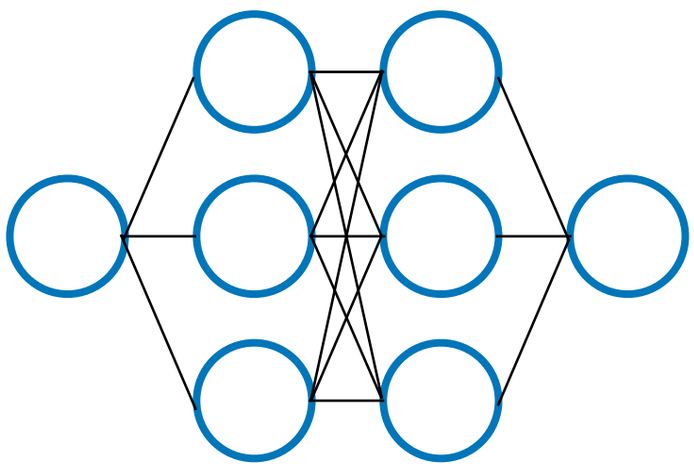
深層学習による最尤推定

x_{ij} ：i 番目の観測の j 個目の点

ℓ_n：負の対数尤度

$$\ell_n = -\frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{N_i}\log(S(x_{ij})) + \int_A S(\boldsymbol{x})m(d\boldsymbol{x})$$

最小化



$\hat{S}$：深層学習による最尤推定量

最尤推定量の理論解析

- ☆ **収束レート（済）**
  - ・どれくらい速く
    真の強度関数に近づくか
- ☆ **minimax最適性（済）**
  - ・収束レートはこれ以上
    改善できるか？
- ☆ **深層学習が他の推定量に比べて良いと言えるか？(未)**

$\mathcal{G}$：真の強度関数が属する関数クラス

$\mathcal{F}$：深層学習が表現する関数

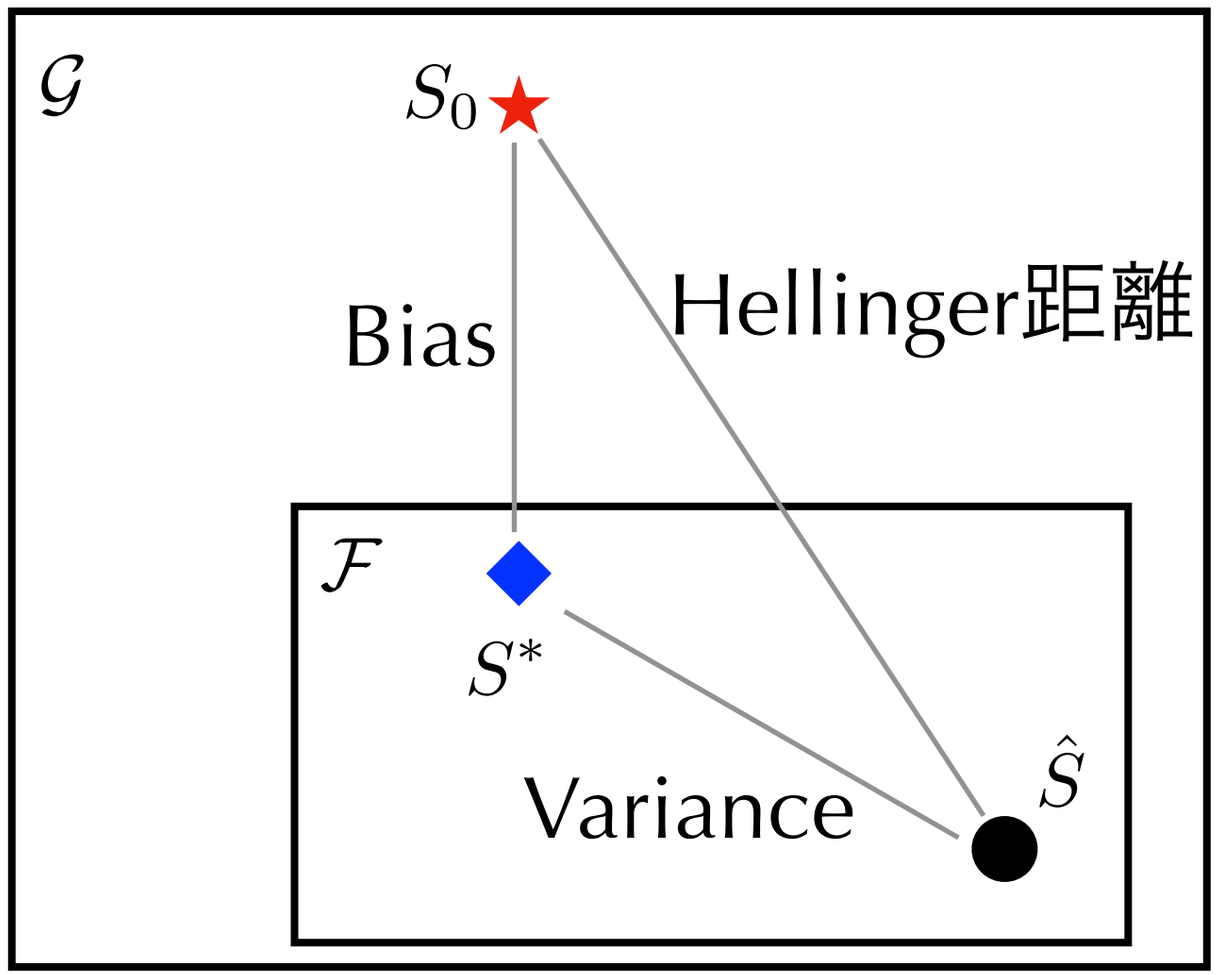
★$S_0 \in \mathcal{G}$：真の強度関数

● $\hat{S} \in \mathcal{F}$：最尤推定量

◆$S^* \in \mathcal{F}$：$\mathcal{F}$上で最適な強度関数

$R(\hat{S}, S_0)$：最尤推定量の超過リスク

$H^2(\hat{S}, S_0)$：Hellinger 距離の二乗



評価が　$R(\hat{S}, S_0) \geq H^2(\hat{S}, S_0)$

✖困難　　○比較的容易

現実的な仮定の下で超過リスク
よりも少し弱い意味での収束を扱う

Bias-Variance分解

$$H^2(\hat{S}, S_0) \leq 2\{H^2(S^*, S_0) + H^2(\hat{S}, S^*)\}$$

Bias　　Variance

Kohler & Langer (2019)など ↓　**Theorem 2** ↓

$$\leq C_{bias} n^{-r_{bias}} + C_{var} n^{-r_{var}}$$

$$\leq C \boxed{n^{-r}}$$ **収束レート**

minimax最適性の確認

$$\inf_{\hat{S}} \sup_{\lambda_0 \in \mathcal{G}} H^2(\hat{S}, S_0) \geq C' \boxed{n^{-r'}}$$ **minimax下界**

$r = r'$なら深層学習はminimax最適
（これ以上改善できない）

2.2 記号と仮定

- **記号**

  - $\bar{\mathcal{F}}_n^{1/2}(\delta) := \left\{ \sqrt{\frac{S + S_n^*}{2}} : H\left(\frac{S + S_n^*}{2}, S_n^* \right) \leq \delta, S \in \mathcal{F}_n \right\}$

  - $N_{p,B}(\delta, \mathcal{F}, Q)$:

    関数クラス $\mathcal{F}$ の $L^p(Q)$ ノルムに関する δ-bracketing number

    - 関数クラス $\mathcal{F}$ のある種の"大きさ"や"複雑度"を表す

  - $J_B(\delta, \bar{\mathcal{F}}_n^{1/2}(\delta), m(d\boldsymbol{x})) = \int_{\delta^2/(2^{10}\sqrt{C_\rho})}^{\delta} \sqrt{\log N_{2,B}(u, \bar{\mathcal{F}}_n^{1/2}(\delta), m_n^*)} du \vee \delta$

    - 局所的な複雑度を表す

    ⇒ 局所的な複雑度を用いることでタイトな不等式を導く

    (van de Geer, 2000; Bartlett et al., 2005)

3.3 Poisson過程の強度関数のノンパラメトリック最尤推定

☆オラクル不等式（推定量の汎化性能を評価）

Theorem 2（オラクル不等式 期待値ver.）

$\hat{S}_n$ をMLEとする. $\Psi(\delta) \geq J_B(\delta, \bar{\mathcal{F}}_n^{1/2}(\delta), m_n^*)$ を $\Psi(\delta)/\delta^2$ が δ の非増加関数となるようにとる. このとき, ある普遍定数 c と

$$\sqrt{n}\delta_n^2 \geq c\Psi(\delta_n) \qquad (1)$$

を満たす δ_n, 全ての $\delta \geq \delta_n$ に対して以下が成り立つ.

$$\mathbb{E}[H^2(\hat{S}_n, S_0)] \leq 514(c_0+1)^2 \left(\underbrace{\delta^2}_{\text{Variance}} + \underbrace{H^2(S_n^*, S_0)}_{\text{Bias}} + \frac{c^3}{n} \right)$$

- δ がVarianceの評価に対応
- J_B はモデル $\mathcal{F}_n$ の"大きさ" = "複雑さ"を表す

⇒ モデルが複雑なほどVarianceは大きくなってしまう

3.3 Poisson過程の強度関数のノンパラメトリック最尤推定

☆オラクル不等式（推定量の汎化性能を評価）

Theorem 2（オラクル不等式 期待値ver.）

$\hat{S}_n$ をMLEとする. $\Psi(\delta) \geq J_B(\delta, \bar{\mathcal{F}}_n^{1/2}(\delta), m_n^*)$ を $\Psi(\delta)/\delta^2$ が δ の非増加関数となるようにとる. このとき, ある普遍定数 c と

$$\sqrt{n}\delta_n^2 \geq c\Psi(\delta_n) \qquad (1)$$

を満たす δ_n, 全ての $\delta \geq \delta_n$ に対して以下が成り立つ.

$$\mathbb{E}[H^2(\hat{S}_n, S_0)] \leq 514(c_0+1)^2 \left(\underbrace{\delta^2}_{\text{Variance}} + \underbrace{H^2(S_n^*, S_0)}_{\text{Bias}} + \frac{c^3}{n} \right)$$

- モデルが複雑なほど Varianceは大きくなってしまう
- 一方, モデルが複雑なほど Bias は小さくなる

（モデルが複雑なほど真の強度関数を含みやすくなるため）

Bias-Variance トレードオフ

3.3 Poisson過程の強度関数のノンパラメトリック最尤推定

☆オラクル不等式（推定量の汎化性能を評価）

Theorem 2（オラクル不等式 期待値ver.）

$\hat{S}_n$ をMLEとする. $\Psi(\delta) \geq J_B(\delta, \bar{\mathcal{F}}_n^{1/2}(\delta), m_n^*)$ を $\Psi(\delta)/\delta^2$ が δ の非増加関数となるようにとる. このとき, ある普遍定数 c と

$$\sqrt{n}\delta_n^2 \geq c\Psi(\delta_n) \qquad (1)$$

を満たす δ_n, 全ての $\delta \geq \delta_n$ に対して以下が成り立つ.

$$\mathbb{E}[H^2(\hat{S}_n, S_0)] \leq 514(c_0+1)^2 \left(\underbrace{\delta^2}_{\text{Variance}} + \underbrace{H^2(S_n^*, S_0)}_{\text{Bias}} + \frac{c^3}{n} \right)$$

- モデルの複雑さ J_B とBiasの評価ができれば

  MLEの収束レートがわかる！
- Theorem 2は深層学習に限らず一般のNPMLEに対して成立