サマーセミナー2023 発表

大阪大学 大学院基礎工学研究科
狩野研究室 M2 屋良 淳朝

8月8日

ロジスティック回帰分析における
ノンパラメトリック最尤推定量の性質

はじめに

- **条件付き確率の推定**
  - 判別分析において，共変量が与えられたときのラベルだけでなく，
    条件付き確率も知りたい状況がある
    - e.g. 人間ドックの検査結果から，ある特定の病気になる確率
  - Cherozhukov et al. (2018) のdouble machine learning (DML)では，
    局外母数のノンパラメトリック推定に$o_p(n^{-1/4})$の収束レートが必要
    - 条件付き確率が局外母数となる場合には，
      その推定量についての理論が必要
  - 他にも，条件付き確率の推定量をプラグインして推定量を構成し，
    その性質を議論する場合，条件付き確率の推定量の理論的性質を
    明らかにしておくことは重要

はじめに

- **ノンパラメトリック推定量の研究**

→ 主に回帰分析と判別分析の枠組み

- 深層学習を用いたノンパラメトリック回帰分析

	Schmidt-Hieber(2020)	**Imaizumi & Fukumizu (2019)**	**Suzuki (2019)**
真の回帰関数が属するクラス	Composition Structured Functions	Piecewise Smooth Function	Besov
活性化関数	ReLU	ReLU	ReLU
収束レート (log factor は無視)	$\max_{i=0,\dots,q} n^{-\frac{2\beta_i^*}{2\beta_i^*+t_i}}$	$n^{-\frac{2\beta}{2\beta+D}} \vee n^{-\frac{\alpha}{\alpha+D-1}}$	$n^{-\frac{2s}{2s+d}}$

* いずれの収束レートも minimax 最適

- Ohn and Kim (2022): 正則化付きのノンパラメトリック回帰についての議論

はじめに

- **ノンパラメトリック推定量の研究**
  - 深層学習を用いたノンパラメトリック判別分析
    - Hu et al. (2020), Kim et al. (2021): 誤判別率の収束に関する結果
    - Ohn and Kim (2022): 正則化付きのノンパラメトリック判別分析において，KLダイバージェンスの収束についての結果（**条件付き確率の収束**）
    - Bos & Schmidt-Hieber (2022): ノンパラメトリック判別分析において，KLダイバージェンスとHellinger距離の収束についての結果（**条件付き確率の収束**）
  - **推定量が陽な表現をもたない場合において，条件付き確率のノンパラメトリック推定の理論的性質については議論は少ない**

- **本研究の目的**

  ロジスティック回帰におけるノンパラメトリック最尤推定量 (NPMLE) の理論的性質の解明

ロジスティック回帰分析

- **問題設定**

  - $\mathcal{X} \subset \mathbb{R}^d$: 入力空間, $\mathcal{Y} = \{\pm 1\}$: 出力空間, P: $\mathcal{X} \times \mathcal{Y}$ 上の未知の分布

  - $(X_1, Y_1), \ldots, (X_n, Y_n) \sim_{i.i.d.} P$: 観測データ, $\mathcal{D} := \{(X_i, Y_i)\}_{i=1}^n$

  - P_X: Xの周辺分布, P_n : 経験分布

  - $p_0(x)$: $X = x$ が与えられた下での$Y = 1$である真の条件付き確率

  - $X = x$ が与えられた下での Y の条件付き確率をロジスティック

    シグモイド関数$\eta(z) := 1/(1 + e^{-z})$を用いて以下でモデル化

$$f_0(x) = \eta^{-1}(p_0(x)) \Leftrightarrow P_{f_0}(Y = 1 \mid X = x) := p_0(x) = \frac{1}{1 + e^{-y f_0(x)}}$$

- **目標：観測データ$\mathcal{D}$ から条件付き確率 $P_{f_0}(Y = \cdot \mid X = x)$ の推定**

ロジスティック回帰分析

- **ノンパラメトリック最尤推定**

  - $\mathcal{F}_n$: 仮説空間（可測関数の集合．ただし，可測関数全体ではない）
  - $L(y, f(x)) := -\log P_f(Y = y \mid X = x) = \log(1 + e^{-yf(x)})$: 損失関数
  - $R_{L,P}(f) := \int_{\mathcal{X}\times\mathcal{Y}} L(y, f(x))dP(x, y)$: リスク
  - $\hat{f}_n$: ノンパラメトリック最尤推定量（NPMLE）

$$R_{L,P_n}(\hat{f}_n) = \inf_{f\in\mathcal{F}_n} \frac{1}{n}\sum_{i=1}^{n} L(Y_i, f(X_i))$$

- **NPMLE $\hat{f}_n$で真のロジット関数 f_0を推定（最尤推定）**

* 本研究では，最適化については考えず，

  NPMLE $\hat{f}_n$が得られるとして議論する

分散の評価

- **超過リスクの下界**
  - 推定量の評価は通常超過リスク$R_{L,P}(\hat{f}_n) - \inf_{f \in L_0(\mathcal{X})} R_{L,P}(f)$の評価によって行われる．ここで，$L_0(\mathcal{X})$ は $\mathcal{X}$ 上の可測関数全体.

    （「はじめに」で挙げたノンパラメトリック推定の研究はいずれも超過リスクの評価を行なっている）
  - しかし，ロジスティック回帰におけるノンパラメトリック最尤推定においては，超過リスクの収束を示すには $\exists F^* > 0; \|f_0\| \leq F^*$

    (Ohn & Kim, 2022)や「真の条件付き確率が0に近い値を取る確率が低い」(informal) (Bos & Schmidt-Hieber, 2022)が必要

    →推定誤差の下界に現れる非類似度を用いた少し弱い意味での収束を扱うことでこの条件を緩和！（van de Geer, 2000 の方法）

分散の評価

- **超過リスクの下界**
  - 本研究で課す条件：$\exists c_0 > 0;\ \frac{P_{f_0}(Y=y|X=x)}{P_{f_n^*}(Y=y|X=x)} \leq c_0^2$
    - $f_n^* \in \mathcal{F}_n$ は固定された仮説空間の元
  - 超過リスクを直接評価するには前ページで示した仮定が必要になる

→超過リスクの解析は諦めて(2)の下で別の非類似度 d で一致性を示す！

- $H^2\left(P_{\hat{f}_n}(\cdot \mid X=x), P_{f_0}(\cdot \mid X=x)\right) := \frac{1}{2}\sum_{y=\pm 1}\left(\sqrt{P_{\hat{f}_n}(y \mid x)} - \sqrt{P_{\hat{f}_0}(y \mid x)}\right)^2$

  ：Hellinger 距離の二乗

- $d^2(P_{\hat{f}_n}, P_{f_0}) := \int H^2\left(P_{\hat{f}_n}(\cdot \mid X=x), P_{f_0}(\cdot \mid X=x)\right) dP_X(x)$

  ：Hellinger 距離の二乗の周辺分布での期待値

分散の評価

- 超過リスクの下界
  - 実は，dは超過リスク下界になっている

Lemma 1（超過リスクの下界）

超過リスク$R_{L,P}(\hat{f}_n) - R_{L,P}(f_0)$に対して，

$$R_{L,P}(\hat{f}_n) - R_{L,P}(f_0) \geq 2d^2(P_{\hat{f}_n}, P_{f_0})$$

が成り立つ.

- KLダイバージェンスとHellinger距離の大小関係からただちにわかる

分散の評価

☆分散の評価

Theorem 1（推定量の分散の評価）

ある関数$\Psi(\delta)$が存在し,$\Psi(\delta) \geq J_B(\delta, \bar{\mathcal{P}}^{1/2}(\delta), \mu)$及び$\Psi(\delta)/\delta^2$が$\delta$の非増加関数となるとする．このとき，定数$c$と$\sqrt{n}\delta_n^2 \geq c\Psi(\delta_n)$を満たす$\delta_n$に対して，以下が成り立つ．

$$d(P_{\hat{f}_n}, P_{f_0}) = O_p(\delta_n + d(P_{f_n^*}, P_{f_0}))$$

- **Theorem 1 によって，関数クラス$\mathcal{F}_n$が定まり，複雑度の評価　が計算できれば，$\sqrt{n}\delta_n^2 \geq c\Psi(\delta_n)$を満たす$\delta_n$を用いて**

  $d(P_{\hat{f}_n}, P_{f_0}) = O_p(\delta_n + d(P_{f_n^*}, P_{f_0}))$となることがわかる

- **Theorem 1 は推定量の分散の評価であり，具体的なモデルのバイアスの評価と合わせることで収束レートを導出することができる**

深層学習における例

☆深層学習における収束レート

- f_0 は Composition Structured Functions, $f_0 \in \mathcal{G}(q, \mathbf{d}, \mathbf{t}, \boldsymbol{\beta}, K)$

Theorem 2（深層学習における収束レート）

$\beta_i^* := \beta_i \prod_{l=i+1}^{q} (\beta_l \wedge 1)$, $\phi_n = \max_{i=0,\ldots,q} n^{-\frac{2\beta_i^*}{2\beta_i^* + t_i}}$ と定義する．また，以下の条件を満たす順伝播型NNモデルの集合 $\mathcal{F}(L, \mathbf{p}, s)$ を考える．

$$\text{(i) } n\phi_n \lesssim \min_{i=1,\ldots,L} p_i, \quad \text{(ii) } s \asymp n\phi_n \log n,$$

$$\text{(iii) } \sum_{i=0}^{q} \log_2(4t_i \vee 4\beta_i) \log_2 n \leq L \lesssim n\phi_n$$

このとき，以下が成り立つ．

$$d(P_{\hat{f}_n}, P_{f_0}) = O_p(\sqrt{\phi_n}\sqrt{L}\log n)$$

- 対数の項を無視すると，d^2 の意味での収束レートは $\max_i n^{-2\beta_i^*/(2\beta_i^* + t_i)}$
- 真の関数が滑らかであるほど，また，次元が低いほど収束が速い

minimax 最適性

☆minimax 最適性

Theorem 3（minimax 最適性）

X_jが $[0,1]^d$ 上の Lebesgue 測度に関する密度をもつ分布に従うとし,

その密度が有界であるとする. このとき, 任意の非負整数 q,

任意の$\boldsymbol{\beta} \in \mathbb{R}^q$, 任意の i に対して, $t_i \leq \min(d_0, \ldots, d_{i-1})$ を満たす

$\mathbf{d}, \mathbf{t}$, 任意の十分大きい$K > 0$に対して, ある正定数 c が存在して

$$\inf_{\hat{f}_n} \sup_{f_0 \in \mathcal{G}(q,\mathbf{d},\mathbf{t},\boldsymbol{\beta},K)} d(P_{\hat{f}_n}, P_{f_0}) \geq c\sqrt{\phi_n}$$

が成り立つ. 下限は全ての推定量についてとる.

- Theorem3 によって, Theorem2 で示した収束レートは

  対数の項を除いて minimax 最適であることがわかる

正則化付き最尤推定

- **Theorem 2 の問題点**
  - Theorem 2 では，NN の非ゼロのパラメータの数 s が未知の真の関数 f_0 に依存しているためどう取れば良いかわからない
  - 実際に NN を学習する際に無数に存在する非ゼロのパラメータのパターンを探索することは事実上不可能

＊ これらの問題は先行研究 (Schmidt-Hieber, 2020; Imaizumi & Fukumizu, 2019; Suzuki, 2019) でも同様に現れる

→Ohn and Kim (2022) と同様に損失に正則化項を加えることでこの問題を解決する

正則化付き最尤推定

- **正則化付き最尤推定**
  - 最尤推定量の代わりに，以下の正則化付き最尤推定量で f_0 を推定

$$\hat{f}_n = \mathrm{argmin}_{f \in \mathcal{F}_n} \left(\frac{1}{n} \sum_{i=1}^{n} L(Y_i, f(X_i)) + J_n(f) \right)$$

  - ここで，$J_n(f)$ は以下のスパース性をコントロールする正則化項

$$J_n(f) := J_{\lambda_n, \tau_n}(f) := \lambda_n \|\theta(f)\|_{\mathrm{clip}, \tau_n}$$

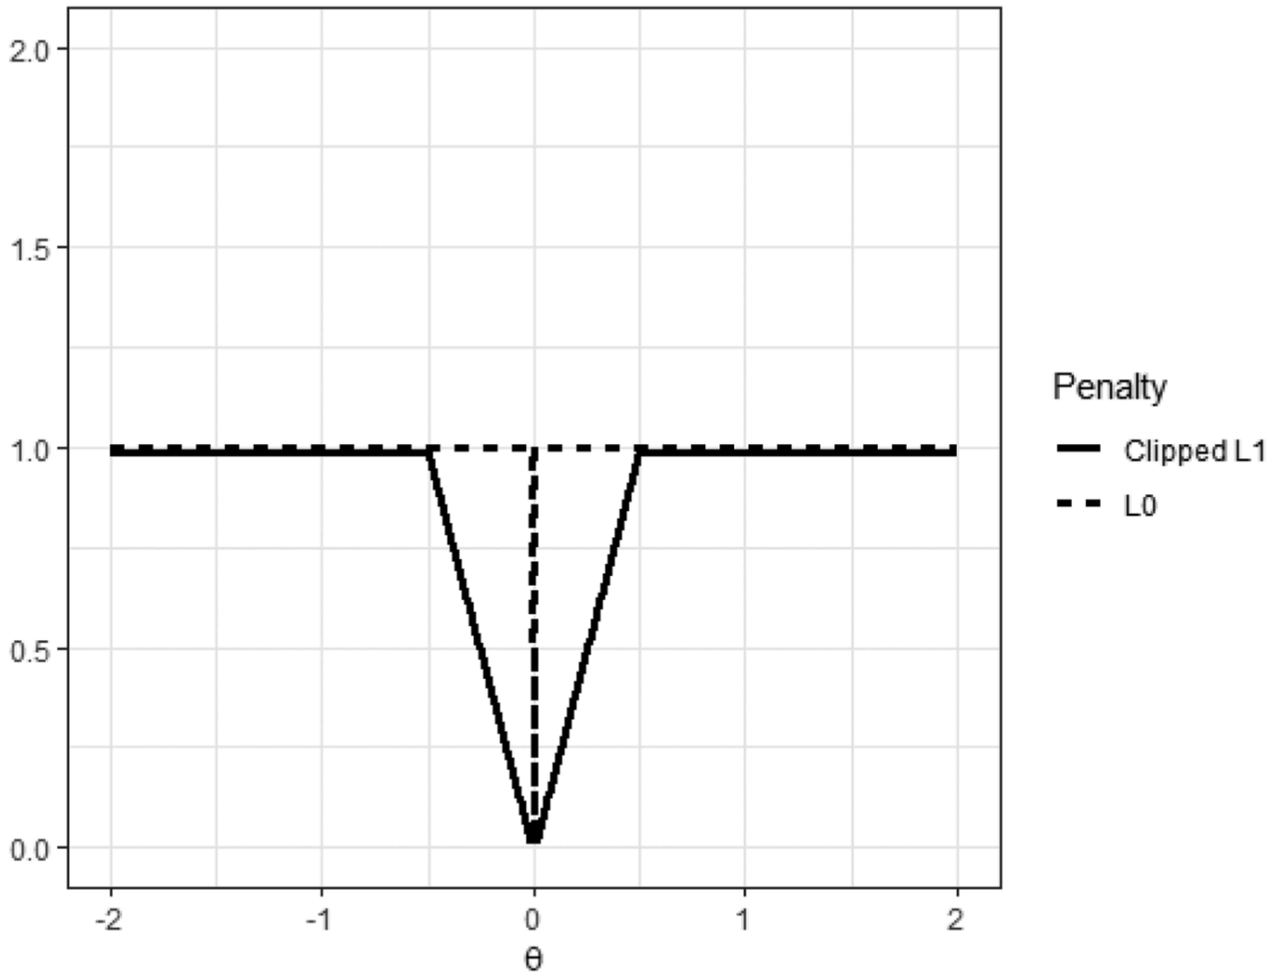
  - $\|\cdot\|_{\mathrm{clip},\tau}$ は clipping threshold τ の cliped L1 ノルム (Zhang, 2010)

で，p 次元ベクトル $\boldsymbol{\theta}$ に対して

$$\|\boldsymbol{\theta}\|_{\mathrm{clip},\tau} := \sum_{j=1}^{p} \left(\frac{\theta_j}{\tau} \wedge 1 \right)$$

正則化付き最尤推定

- **正則化付き最尤推定**
  - $\|\cdot\|_{\text{clip},\tau}$ は L0 ノルム（非ゼロのパラメータの数）を連続に緩和したものになっている
  - 連続性によって最適化が容易になる



Ohn & Kim (2022) より

正則化付き最尤推定

- 正則化付き最尤推定量の分散の評価

Result 1（推定量の分散の評価）

ある関数$\Psi(\delta)$が存在し,$\Psi(\delta) \geq J_B(\delta, \bar{\mathcal{P}}^{1/2}(\delta), \mu)$及び$\Psi(\delta)/\delta^2$が$\delta$の非増加関数となるとする．このとき，定数$c$と$\sqrt{n}\delta_n^2 \geq c\Psi(\delta_n)$を満たす$\delta_n$に対して，以下が成り立つ．

$$d(P_{\hat{f}_n}, P_{f_0}) = O_p\left(\delta_n + \inf_{f\in\mathcal{F}_n} d(P_f, P_{f_0}) + \frac{\inf_{f\in\mathcal{F}_n}(d^2(P_f, P_{f_0}) + J_n(f) + \frac{1}{n})}{\inf_{f\in\mathcal{F}_n} d(P_f, P_{f_0})}\right)$$

- Result 1 と，cliped L1 ノルムが L0 ノルムの上界になっていることを用いると，f_0 に依存するスパース性の条件を課す事なく推定量の収束レートを導出できる
- しかし，評価が tight でないため，minimax 最適なレートを導出できない（現在より良い評価を導出中）

まとめ・今後の課題

- まとめ
  - ☆ロジスティック回帰分析の収束レートを求めるための汎用的な不等式を示した (Theorem1)
  - ☆Theorem1 の適用例として，深層学習におけるロジスティック回帰の収束レートを導出した (Theorem2)
  - ☆Theorem2 で導出したレートの minimax 最適性を示した (Theorem3)
  - ☆正則化付きの場合について推定量の分散の評価を行なった (Result 1)
- 今後の課題
  - ☆正則化付きの場合の評価の改善
  - ☆数値計算による検証

参考文献

Sara A Geer, Sara van de Geer, and D Williams. Empirical Processes in M-estimation, volume 6. Cambridge university press, 2000.

Evarist Giné and Richard Nickl. Mathematical Foundations of Infinite-Dimensional Statistical Models, volume 40. Cambridge University Press, 2016.

Yongdai Kim, Ilsang Ohn, and Dongha Kim. Fast convergence rates of deep neural networks for classifi-cation. Neural Networks, 138:179–197, 2021.

Johannes Schmidt-Hieber. Nonparametric regression using deep neural networks with ReLU activation function. The Annals of Statistics, 48(4):1875 – 1897, 2020.

Taiji Suzuki. Adaptivity of deep ReLU network for learning in Besov and mixed smooth Besov spaces: optimal rate and curse of dimensionality. In International Conference on Learning Representations, 2019.

Martin J Wainwright. High-dimensional statistics: A non-asymptotic viewpoint, volume 48. Cambridge University Press, 2019.

Victor Chernozhukov, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, Whitney Newey, James Robins. Double/debiased machine learning for treatment and structural parameters. The Econometrics Journal, Volume 21, Issue 1, 1 February 2018, Pages C1–C68

参考文献

Imaizumi, M., & Fukumizu, K. (2019). Deep neural networks learn non-smooth functions effectively. In Proceedings of the International Conference on Artificial Intelligence and Statistics.

Ilsang Ohn, Yongdai Kim; Nonconvex Sparse Regularization for Deep Neural Networks and Its Optimality. Neural Comput 2022; 34 (2): 476–517.

Zhang, C.-H. (2010a). Nearly unbiased variable selection under minimax concave penalty. Annals of Statistics, 38(2), 894–942. 10.1214/09-AOS729

付録

- 記号
  - μ：$\{\pm 1\}$ 上のBernoulli測度とP_X の直積測度
  - $\bar{\mathcal{P}}_n^{1/2}(\delta) = \left\{ \left(\frac{P_f + P_{f_n^*}}{2} \right)^{1/2} \middle| d\left(\frac{P_f + P_{f_n^*}}{2}, P_{f_n^*} \right) \leq \delta,\ f \in \mathcal{F}_n \right\}$
  - $\mathcal{N}(\delta, \mathcal{F}, \mu)$: 関数クラス$\mathcal{F}$ の$L^2(\mu)$ノルムに関するbracketing number
  - $\mathcal{H}(\delta, \mathcal{F}, \mu) := \log \mathcal{N}(\delta, \mathcal{F}, \mu)$: bracketing entropy
  - $J_B\left(\delta, \bar{\mathcal{P}}_n^{1/2}(\delta), \mu\right) := \int_{\delta^2/2^{13}}^{\delta} \mathcal{H}^{1/2}\left(u, \bar{\mathcal{P}}_n^{1/2}(\delta), \mu\right)\ du \vee \delta$
  - J_B は条件付き確率のクラスを$P_{f_n^*}$ の近くで見たときの局所的な複雑度を表しており，これを用いることでtight な不等式を導く

付録

▸ 仮説空間（推定モデル）の設定

- $\sigma(x) := \max(0, x)$: 活性化関数, $\mathbf{v} = (v_1, \ldots, v_r) \in \mathbb{R}$: バイアス

- $\sigma_{\mathbf{v}}(y_1, \ldots, y_r) = (\sigma(y_1 - v_1), \ldots, \sigma(y_r - v_r))$:バイアス込みの活性化関数

- L : 隠れ層の数, $\mathbf{p} = (p_0, \ldots, p_{L+1})$: 各層の幅,

- $W_j \in \mathbb{R}^{p_{j+1} \times p_j}$: 重み行列, $\mathbf{v}_i \in \mathbb{R}^{p_i}$: バイアス

- ネットワーク構造 $(L, \mathbf{p})$ の順伝播型ニューラルネットワーク：

$$f : \mathbb{R}^{p_0} \to \mathbb{R}^{p_{L+1}},\ \mathbf{x} \mapsto f(\mathbf{x}) = W_L \sigma_{\mathbf{v}_L} W_{L-1} \sigma_{\mathbf{v}_{L-1}} \cdots W_1 \sigma_{\mathbf{v}_1} W_0 \mathbf{x} \quad (\star)$$

- $\mathcal{F}(L, \mathbf{p}) := \left\{ \text{f of the form } (\star) : \max_{j=0,\ldots,L} \|W_j\|_\infty \vee |\mathbf{v}_j|_\infty \leq 1 \right\}$

- $\|W_j\|_0$: W_j の 0 でない成分の数

  $\mathcal{F}(L, \mathbf{p}, s) := \left\{ f \in \mathcal{F}(L, \mathbf{p}) : \sum_{j=0}^{L} (\|W_j\|_0 + |\mathbf{v}_j|_0 \leq s) \right\}$

付録

- **問題設定：真の関数クラス**

  - smoothness βのHölder 空間：

$$\mathcal{C}_r^{\beta}(D,K) = \Bigg\{ f : D \subset \mathbb{R}^r \to \mathbb{R} : \sum_{\alpha:|\alpha|<\beta} \|\partial^{\alpha} f\|_{\infty} + \sum_{\alpha:|\alpha|=\lfloor\beta\rfloor} \sup_{\mathbf{x},\mathbf{y}\in D,\, \mathbf{x}\neq\mathbf{y}} \frac{|\partial^{\alpha} f(\mathbf{x}) - \partial^{\alpha} f(\mathbf{y})|}{|\mathbf{x}-\mathbf{y}|_{\infty}^{\beta-\lfloor\beta\rfloor}} \leq K \Bigg\}$$

  - Hölder 空間の元の合成で書ける関数の集合：

$$\mathcal{G}(q,\mathbf{d},\mathbf{t},\boldsymbol{\beta},K) = \{ f = g_q \circ \cdots \circ g_0 \mid g_i = (g_{ij})_j : [a_i,b_i]^{d_i} \to [a_{i+1},b_{i+1}]^{d_{i+1}},$$
$$g_{ij} \in \mathcal{C}_{t_i}^{\beta_i}([a_i,b_i]^{t_i},K), \text{for some} |a_i|,|b_i| \leq K \}$$