深層学習を用いた共変量付きポアソン過程に対するノンパラメトリック回帰

屋良 淳朝 / 大阪大学
寺田 吉壱 / 大阪大学, 理研AIP

Introduction

☆深層学習とその理論解析

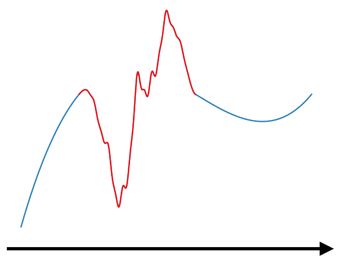
- 深層学習は，現実世界の様々な問題で極めて高い性能を発揮
  - e.g., 画像認識，自然言語処理
- 2024年ノーベル賞は深層学習関連が2つ！



- 深層学習がなぜうまくいくのかを明らかにすることも重要
- 理論解析によって深層学習の様々な利点が明らかに
  - 深層学習は次元の呪いを回避できる;
    mixed-Besov空間 (Suzuki, 2019), 合成関数 (Schmidt-Hieber, 2020)

仮定	なし	背後に低次元構造
収束レート (データ数の指数部分)	$-\frac{2\beta}{2\beta+d}$	$-\frac{2\beta}{2\beta+d^*}$

β: 滑らかさ
$d^* \ll d$



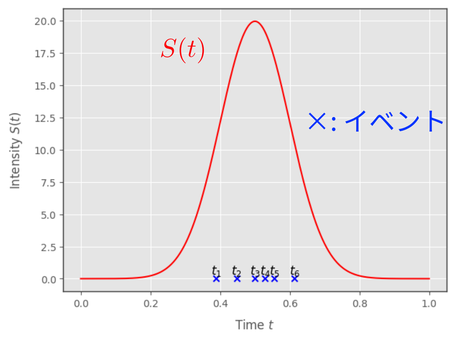
  - 適応的推定能力; Besov空間 (Suzuki, 2019)

☆ポアソン過程

- 時空間のランダムな事象の発生を記述する数理モデル
- ポアソン過程 X の定義（簡単のため $[0,1]$上のポアソン過程）
  - X は $[0,1]$ 上の非負整数値ランダム測度（点の個数を測る）
  - $X(\{0\}) = 0,\ a.s.$
  - $0 \le t_1 < \cdots < t_N \le 1$ に対して，$X([t_1,t_2)), \ldots, X([t_{N-1},t_N))$ は独立な確率変数
  - $0 \le s < t \le 1$ に対して，$X([s,t))$ は強度 $\int_s^t S(\tau)d\tau$ のポアソン分布に従う

強度関数

その時刻における事象の起こりやすさを表現



- 現実のデータでは，強度関数は注目しているイベントに対して固定されているのではなく，様々な要因で変化する
  ⇨ 共変量 Z によって変化する強度関数を考える

$$X \mid Z \sim \text{Poisson process}(S(\cdot \mid Z))$$

応用例	強度関数	強度関数の変化の要因
山火事の出火点 (D'Angelo et al., 2025)	ある座標における出火の起こりやすさ	気温・湿度・風速など
事件の発生場所 (Hart et al., 2022)	ある座標における事件発生率	気温・降水量など

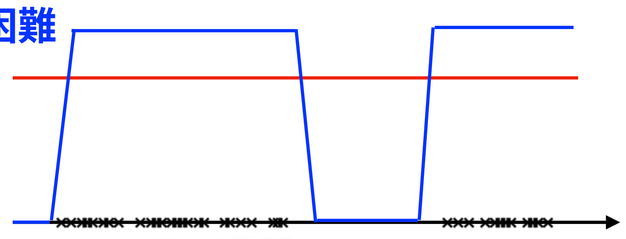
☆ノンパラメトリック最尤推定量の理論評価の困難性

- 強度関数はしばしば最尤推定によって推定される（Kutoyants, 2012）
- 強度関数の最尤推定の場合，超過リスクは真のPoisson過程と推定したPoisson過程の間のKullback-Leibler (KL)ダイバージェンス

$$\mathrm{KL}(P_f, P_g) = \int \left(f \log\left(\frac{f}{g}\right) + g - f \right) d\nu$$

P_h: h を強度関数としてもつポアソン過程の分布

- **しかし，KLは容易に発散することが知られている**
  ⇒ 従来の汎化誤差解析は難しい😞
- **推定量のサポートが真の強度関数のサポートを覆っていなければ発散**
  ⇨ **汎化誤差の評価が困難**



- Bounded away from zero ⇨ 速い収束レート
  - 真の強度関数が bounded away from zero (Kirichenko & Zanten, 2015) ⇨ 収束レートは $n^{-\frac{2\beta}{2\beta+d}}$
  - 仮定なしの場合 ⇨ ?, その中間の条件 ⇨ ?

☆本研究の目標

詳細は補足資料参照

- **共変量付きのポアソン過程の強度関数の最尤推定量の理論的性質**
- **深層学習を用いた場合の理論的性質**

最尤推定の詳細は補足資料参照

Theory & Experiments

☆記号と仮定

- $\tilde{H}^2(S_1, S_2) := \mathbb{E}_Z \left[\frac{1}{2} \int_A (\sqrt{S_1(\boldsymbol{x} \mid Z)} - \sqrt{S_2(\boldsymbol{x} \mid Z)})^2 d\boldsymbol{x} \right]$
  - **KLの代わりにこの量を評価**
- $\mathcal{F}(L, r, B)$: 深さL, 各層の幅 r, パラメータの大きさの上界BのDNN
  - **最終層も含めてすべての活性化関数は** $\mathrm{ReLU}(x) = \max(x, 0)$
- 仮定：

$$\exists c_0 > 0,\ \forall n \in \mathbb{N},\ \exists S_n^* \in \mathcal{F}_n,\ \forall \boldsymbol{x} \in A,\ \forall \boldsymbol{z} \in C;\ \frac{S_0(\boldsymbol{x} \mid \boldsymbol{z})}{S_n^*(\boldsymbol{x} \mid \boldsymbol{z})} \le c_0^2$$

  - 仮説空間のある元が真の強度関数のサポートを覆っている
  - DNNを用いた推定では自動的に満たされる

☆オラクル不等式

Theorem 1（オラクル不等式）

ポアソン過程の条件付き強度関数の推定を考える.
δ_n とある普遍定数 c は

$$\sqrt{n}\delta_n^2 \ge c\Psi(\delta_n)$$

を満たすとする．このとき任意の $\delta \ge \delta_n$ に対して
いくつかの仮定の下で, 以下が成り立つ.

Variance

$$\mathbb{E}[\tilde{H}^2(\hat{S}_n, S_0)] \le 514(c_0+1)^2 \left(\delta^2 + \frac{c^3}{n} + \frac{\tilde{H}^2(S_n^*, S_0)}{\text{Bias}^2} \right)$$

- **$\Psi(\delta)$はモデルの複雑さに対応**　Ψは非負単調非減少
- 複雑さとBiasの評価ができれば最尤推定量の収束レートがわかる！
- Theorem 1は深層学習に限らず一般の最尤推定量に対して成立

☆深層学習における収束レート

- 滑らかさβ, 定義域 D, ノルムの上限 Q のヘルダー空間：$\mathcal{C}^\beta(D, Q)$
- ヘルダー空間の元の合成でかける関数の集合：

$$\mathcal{G}_{\text{comp}}(q, \mathbf{d}, \mathbf{t}, \boldsymbol{\beta}, Q) = \{ f = \boldsymbol{g}_q \circ \cdots \circ \boldsymbol{g}_0 : \boldsymbol{g}_i = (g_{ij})_j : [a_i, b_i]^{d_i} \to [a_{i+1}, b_{i+1}]^{d_{i+1}},$$
$$g_{ij} \in \mathcal{C}^{\beta_i}([a_i, b_i]^{t_i}, Q), \text{for some} |a_i|, |b_i| \le Q \}$$

  - $f(x_1, x_2, x_3) = g_1 \circ \boldsymbol{g}_2(x_1, x_2, x_3) = g_{11}(g_{01}(x_1, x_3), g_{02}(x_1, x_2))$
    （f: 3次元, g_{01}, g_{02}: 2次元）
  - **背後に低次元構想がある**
- 真の強度関数の定義域が低次元多様体：
  - $D = \mathcal{M} \times C$
  - $\mathcal{M} \subset A$ は$d_{\mathcal{M}} < d_1$次元のコンパクトなリーマン多様体
- Theorem 1を適用することで，真の関数クラスを固定した下で深層学習における収束レートが導出できる

関数クラス	$\mathcal{C}^\beta(\mathcal{M} \times C, Q)$	$\mathcal{G}_{\text{comp}}$
収束レート (データ数の指数部	$-\frac{\beta}{\beta + d_{\mathcal{M}} + d_2}$	$-\max_{i=0,\ldots,q} \frac{\beta_i^*}{\beta_i^* + t_i}$

- **深層学習は背後の低次元構造を適切に捉えることができる**
- $\mathcal{G}_{\text{comp}}$ の場合は深層学習における収束レートは
  ミニマックス最適（これ以上改善できない最適な性能を発揮）
- **データの背後のポアソン仮定がリーマン多様体の場合は**
  リーマン多様体の構造に自動的に適応できる！

☆数値実験

数値実験の詳細は捕捉資料参照

