ノンパラメトリック・
ロジスティック回帰の統計理論

屋良 淳朝[1]，寺田 吉壱[1, 2]

[1]大阪大学 大学院基礎工学研究科
[2]理化学研究所 革新知能統合研究センター (AIP)

2025/10/31 大規模複雑データの理論と方法論の深化:最前線の動向と新たな展開
@イーアスホール

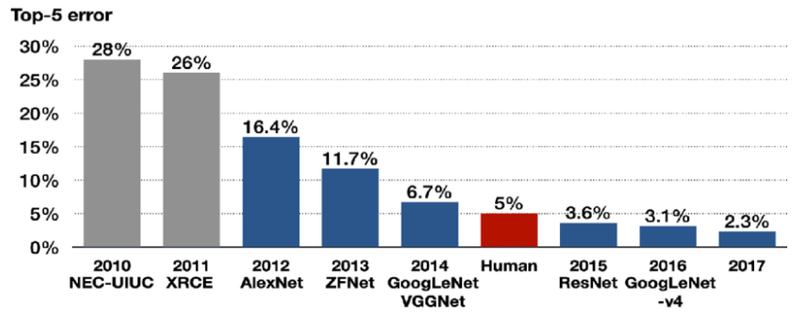
Yara, A. and Terada, Y., Nonparametric logistic regression with deep learning, 2025+, Bernoulli

深層学習

⭐深層学習は現実世界の様々な問題で極めて高い性能を発揮

画像認識

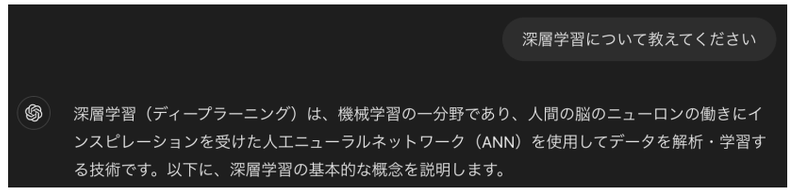
ILSVRCで優勝した
AlexNet (Krizhevsky et al., 2012) が
深層学習ブームの火付け役



[Kang et al., 2020]

自然言語処理

Transformer登場以降劇的に精度が向上



[ChatGPT, OpenAI]

⭐2024年ノーベル賞は深層学習関連が2つ!

物理学賞

人工ニューラルネットによる
機械学習

化学賞

AIによるタンパク質構造予測



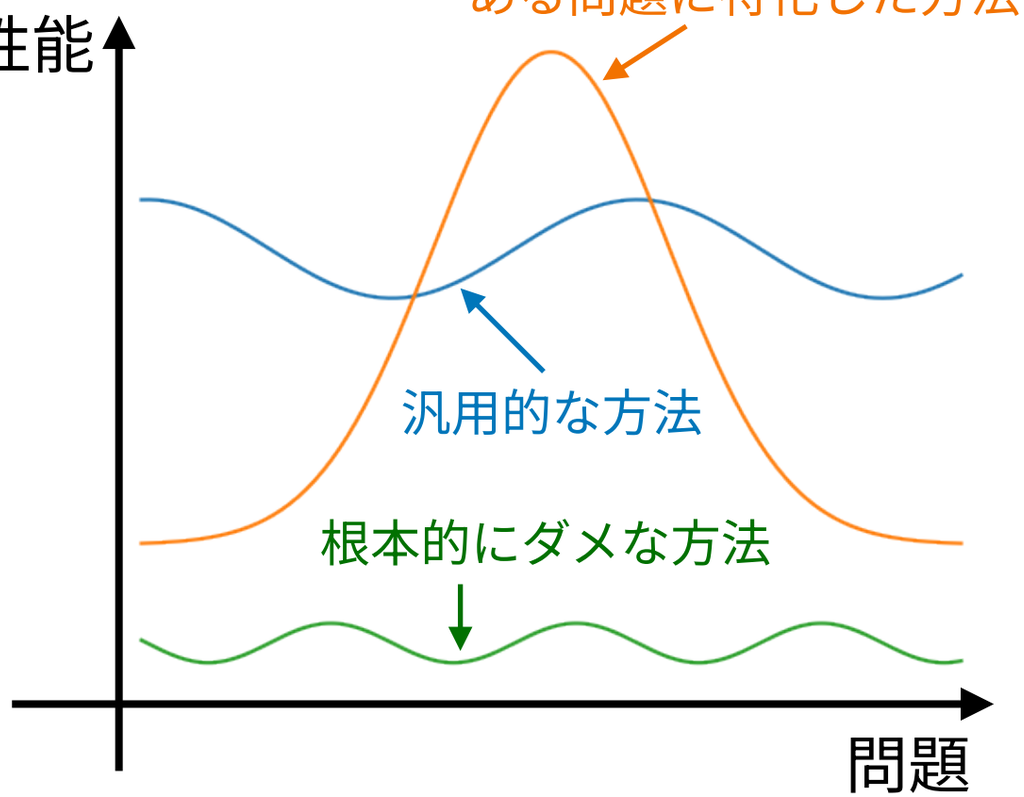
深層学習の理論解析

⭐深層学習がなぜうまくいくかを明らかにすることも重要

全ての問題に対して万能な学習法は存在しない

- No-free-lunch theorem
- Slow rates of convergence

⇒ **様々な手法の開発，各手法がうまくいく状況を明らかにすることが重要**



⭐様々な方向性の理論研究

- **深層学習の汎化性能に関して (汎化誤差解析) ← 本研究**
- 深層学習の近似性能に関して
- 深層学習の最適化に関して

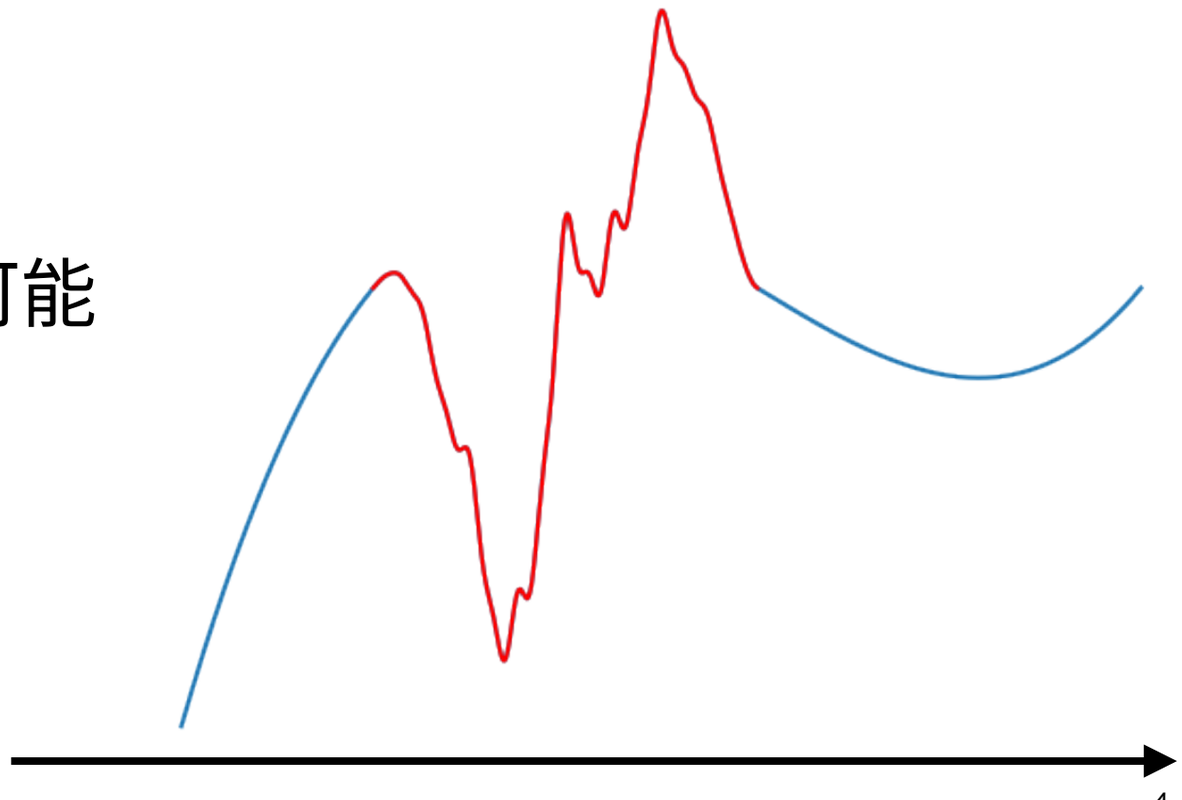
深層学習の理論的利点

⭐深層学習は次元の呪いを回避できる

- 回帰
  - mixed-Besov空間 (Suzuki, 2019)
  - 合成関数 (Schmidt-Hieber, 2020)
- 分類
  - GMM + ノイズ条件 (Zhou and Huo, 2024)
  - 合成関数 (Yara and Terada, 2025+)

⭐適応的推定能力

- 滑らかな部分とそうでない部分が
  混在する場合などに効率よく推定可能
  - e.g. Besov空間 (Suzuki, 2019)



分類問題の設定

⭐分類問題の基本的な設定

- K クラスの分類問題を考える
  - $\mathcal{X} \subset \mathbb{R}^d$：入力空間（コンパクト），$\mathcal{Y} = \{1, \ldots, K\}$：出力空間
  - P : $\mathcal{X} \times \mathcal{Y}$ 上の確率分布，$P_{\boldsymbol{X}}$：X の周辺分布
  - $(\boldsymbol{X}, Y), (\boldsymbol{X}_1, Y_1), \ldots, (\boldsymbol{X}_n, Y_n) \sim_{i.i.d.} P$
  - $\mathcal{D}_n := \{(\boldsymbol{X}_i, Y_i)\}_{i=1}^n$：観測データ
  - $\eta_k(\boldsymbol{x}) := P(Y = k \mid \boldsymbol{X} = \boldsymbol{x})$, $\boldsymbol{\eta}(\boldsymbol{x}) = (\eta_1(\boldsymbol{x}), \ldots, \eta_k(\boldsymbol{x}))^T$
  - データ$\boldsymbol{X}$ が与えられた下で, Y は以下の多項分布に従う

$$Y|\boldsymbol{X} = \boldsymbol{x} \sim \mathrm{Multi}(\boldsymbol{\eta}(\boldsymbol{x}))$$

- **分類問題の目標：**
  新たなデータX が与えられたときに, Y を良く予測するような関数
  $f : \mathcal{X} \to \{1, \ldots, K\}$**（決定関数）を見つけること**

分類問題の設定

⭐学習の方法

- 学習 = 観測データ $\mathcal{D}_n$ から決定関数 f を求めること
- 経験誤差最小化（ERM）がよく用いられる
- ERM = 観測データ上で損失関数を最小化
- ℓ を損失関数，$\mathcal{F}_n$ を仮説空間（推定量の候補）とすると ERM $\hat{f}_n$ は

$$\hat{f}_n \in \underset{f \in \mathcal{F}_n}{\arg\min} \frac{1}{n} \sum_{i=1}^{n} \ell(Y_i, f(\boldsymbol{X}_i))$$

- 得られた決定関数の推定量を元に，$\boldsymbol{X}$ が与えられたときの Y を予測
- さまざまな損失関数が用いられる
  - ヒンジロス：$l(y, f(x)) := 0 \vee (1 - yf(x))$
  - ロジスティックロス：$l(y, f(x)) := \log(1 + e^{-yf(x)})$

条件付き確率の推定

⭐条件付き確率の推定

- ヒンジロスを用いた場合は，分類器そのものしか構成できない
  i.e. ラベルの予測しかできない
- 条件付き確率を推定できた方が便利な状況もある
  - 📌 e.g. AI ベースの病気の診断
- 条件付き確率を推定できれば，その確率を元に人間の意思決定に役立てることができる！
- 条件付き確率を推定する方法
  ⇒ **損失関数として負の対数尤度を利用（最尤推定）**
- ノンパラメトリック最尤推定量（NPMLE）：

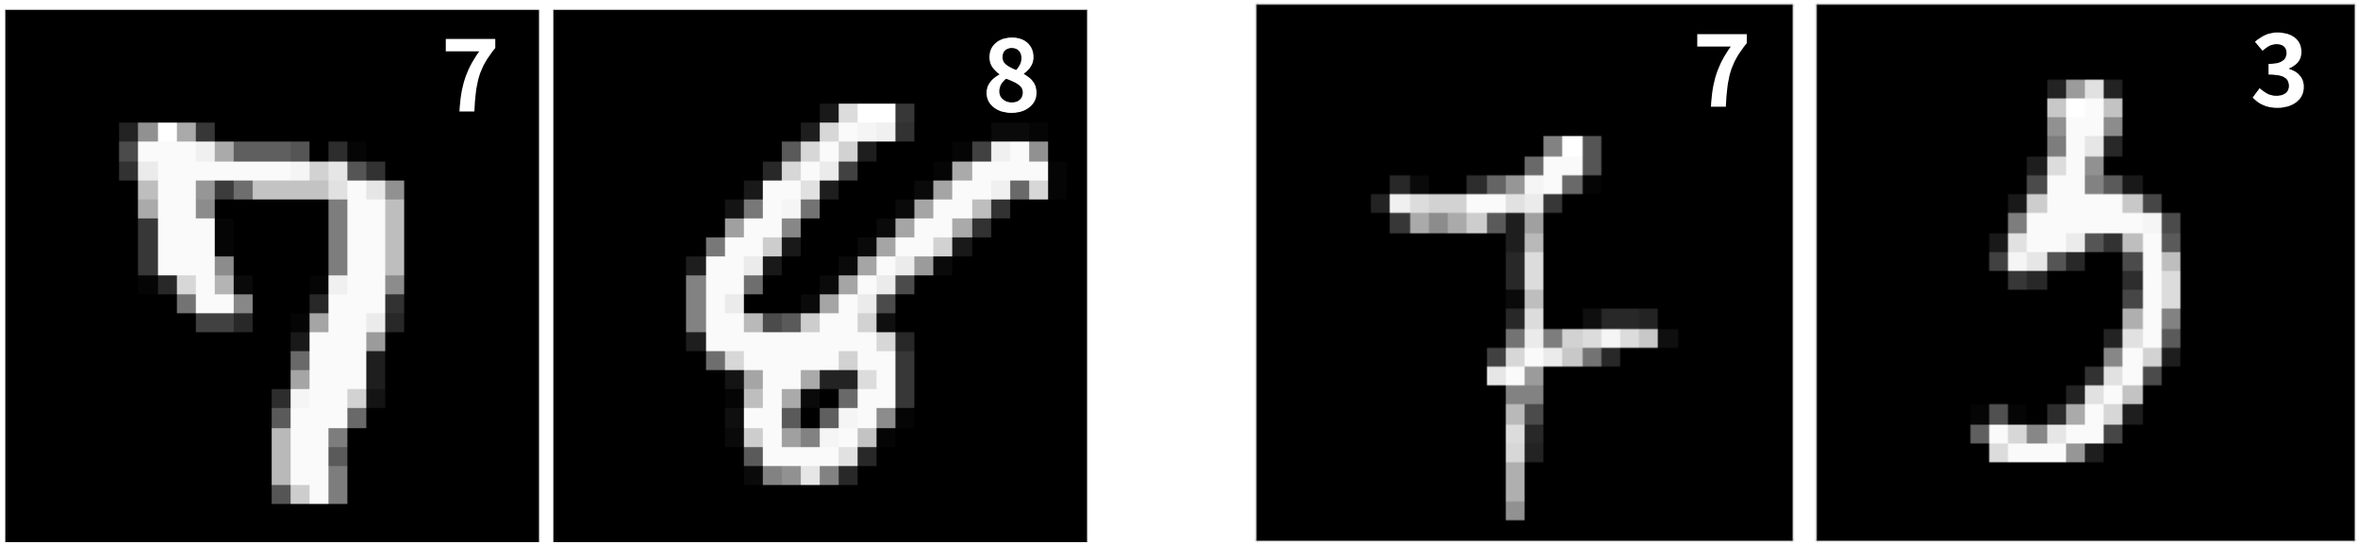
$$\ell(\boldsymbol{p}) := -\frac{1}{n}\sum_{i=1}^{n} \boldsymbol{Y}_i^\top \log \boldsymbol{p}(\boldsymbol{X}_i),\ \hat{\boldsymbol{p}}_n \in \operatorname*{arg\,min}_{\boldsymbol{p}\in\mathcal{F}_n} \ell(\boldsymbol{p})$$

  - 📌 $\boldsymbol{Y}_i$ は Y_i の one-hot 表現，i.e. $\boldsymbol{Y}_i = (0,\ldots,\underset{k}{1},\ldots,0)$ if $Y_i = k$

深層学習を用いた条件付き確率の推定

⭐深層学習を用いたロジスティック回帰

- 分類問題においては，出力層にソフトマックス関数を用いたDNNを用いた最尤推定で条件付き確率の推定が可能
  - ロジスティックロスを用いたERMと等価 ⇨ ロジスティック回帰
- MNIST における分類の例（kNNと比較）
  - **判別がつきにくいものは条件付き確率も小さく推定されている**



DNN	**4: 10%, 7: 90%**	**4: 10%, 8 : 90%**	**7: 60%, 8 : 40%**	**3: 60%, 4: 10%, 5: 30%**
kNN	7: 80%, 9: 20%	4: 30%, 8 : 20%, 9: 50%	1: 100%	3: 40%, 5: 50%, 9: 10%

セミパラメトリック推定への応用

⭐Double/Debiased Machine Learning (DML) との関係

- 因果推論の文脈において, 傾向スコア（＝共変量を条件付けたときの割り付けの**条件付き確率**）は因果効果を推定する際の局外母数として重要な役割を果たす
- DML (Chernozhukov et al., 2018)：
  傾向スコアなどの局外母数の推定に機械学習の手法を用いる方法
  ⇒ **局外母数が複雑な状況でも自然な推定量を提供**
- 局外母数の推定に$o_p(n^{-1/4})$の収束レートを示す必要がある
  ⇒ 例えば, 傾向スコアを深層学習を用いて推定する場合を考えると
  深層学習を用いたロジスティック回帰の汎化誤差解析が必須！
- （別の問題として,,,）傾向スコアの推定の応用でよく用いられる
  IPW推定量は傾向スコアがゼロに近いと非常に不安定となる
  ⇒ ELW推定量 (Liu & Fan, 2023) を用いればOK! (詳細は付録)

ノンパラメトリック最尤推定の困難性

☆様々な設定におけるノンパラメトリック最尤推定

- **回帰**
  - 誤差に正規性を過程すると汎化誤差は
    二乗誤差 ⇒ 真の回帰関数が有界であれば二乗誤差も有界
  - 真の回帰関数の有界性は妥当
- **クラス条件付き確率の推定（分類）**
  - 汎化誤差は真の条件付き確率と推定量との
    KLダイバージェンス ⇒ 一般に非有界，容易に発散
  - 評価するためには真の条件付き確率が
    bounded away from zeroであることが必要

$$c < \mathbb{P}(Y = 1 \mid \boldsymbol{x}) < C, \quad 0 < c, C < 1$$

二値分類の場合

ノンパラメトリック最尤推定の困難性

⭐KLダイバージェンスの発散に対する対処法

- 真の条件付き確率に制約 (Ohn & Kim, 2022, Neural Comput.):
  - 📌 真の条件付き確率が bounded away from zero (BAFZ) と仮定
    - 👍 汎化誤差の収束レートが導出可能
    - ⚠️ 条件付き確率が極端な値 (0 or 1)をとる場合に対応できない
- 推定量を改変 (Bilodeau et al., 2023, Ann. Stat.):
  - 📌 推定量を bounded away from zero となるように改変
  - 📌 仮説空間が真の条件付き確率を含むと仮定
    - 👍 汎化誤差の収束レートが導出可能
    - ⚠️ 仮説空間が真の条件付き確率を含まない場合に対応できない
- **評価指標の取り替え ← 本研究**
  - 📌 Bos & Schmidt-Hieber (2022, Electron. J. Stat.):
    打ち切り KL ダイバージェンス
  - 📌 **Yara & Terada (2025, Bernoulli): Hellinger 距離**
    - 👍 真の構造に仮定が不要

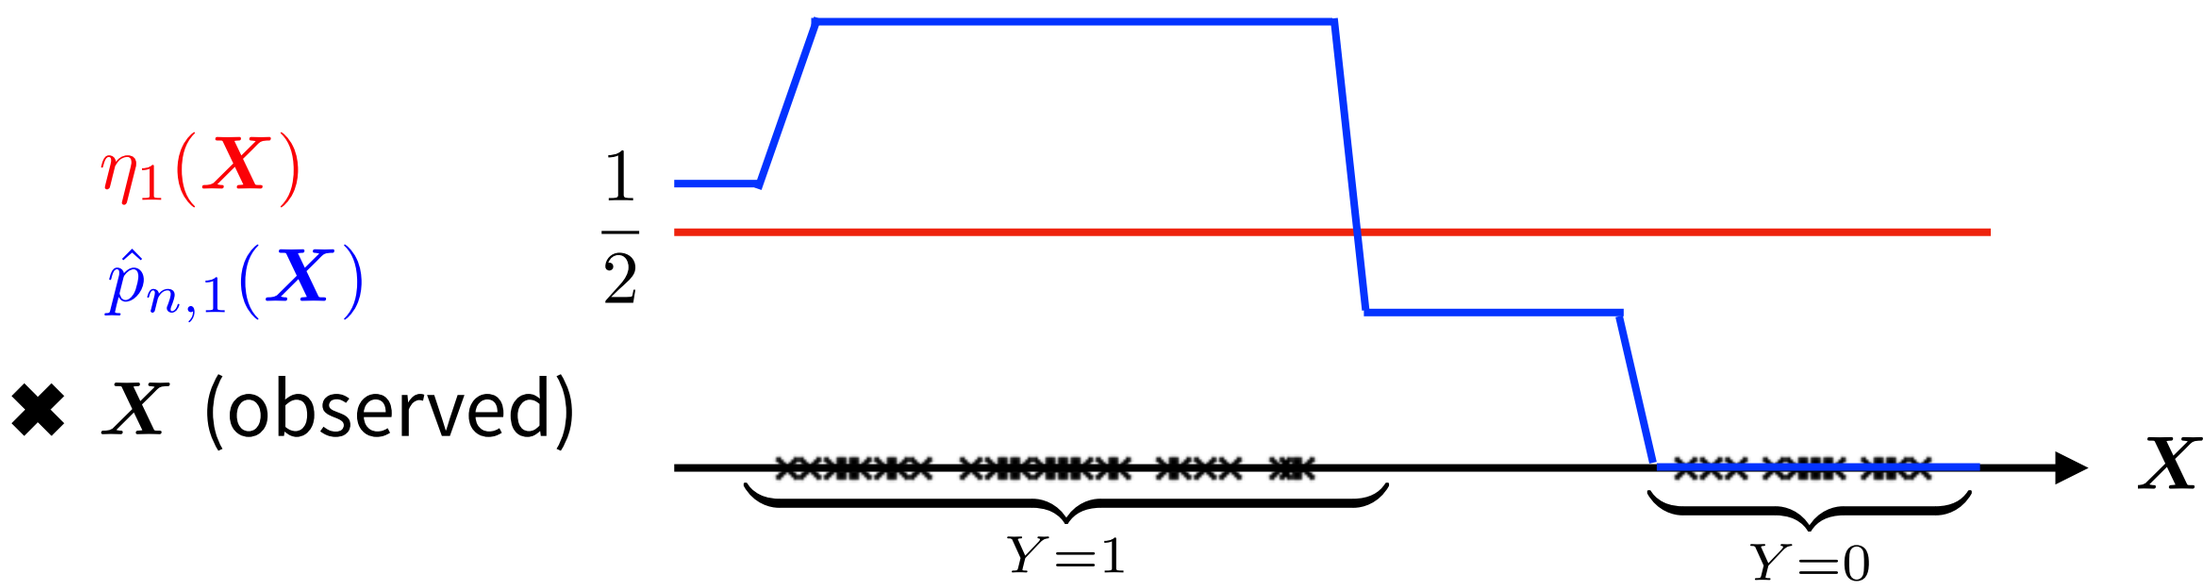
ノンパラメトリック最尤推定の困難性

⭐KLダイバージェンス（の期待値）が発散する例

- KLダイバージェンスには**条件付き確率の比**が登場

$$\mathbb{E}_{\boldsymbol{X}}[\mathrm{KL}(\boldsymbol{\eta}(\boldsymbol{X}) \,\|\, \hat{\boldsymbol{p}}_n(\boldsymbol{X}))] = \mathbb{E}_{\boldsymbol{X}}\left[\boldsymbol{\eta}(\boldsymbol{X})^\top \log\left(\frac{\boldsymbol{\eta}(\boldsymbol{X})}{\hat{\boldsymbol{p}}_n(\boldsymbol{X})}\right)\right]$$

- 推定量のサポートが真の条件付き確率の台を
覆っていなければ発散 ⇒ **汎化誤差の評価が困難**



本研究の目標

- ⭐**条件付き確率のノンパラメトリック最尤推定量の理論的性質を明らかにする**
  - **ノンパラメトリック最尤推定において, KLの評価は困難**

    例えば, Ohn and Kim (2022) ではbounded away from zeroの仮定が必要に …

    ⇒ van de Geer (2000) のアプローチを用いて

    Hellinger距離を直接評価することで解決

    - **強い仮定が不要, 証明の見通しが良い！**
- ⭐**深層学習を用いた最尤推定量の評価**
  - **深層学習を用いたロジスティック回帰分析の理論解析へ応用**
    - **判別問題においても, 次元の呪いを回避できる可能性が示唆**
  - **深層学習がミニマックス最適であることを証明**
    - **深層学習はこれ以上改善できない最適な収束レートを達成**

先行研究との比較

⭐先行研究との比較

	評価指標	損失関数	備考
Hu et al. (2020, arXiv)	誤判別率	0-1損失 ヒンジロス	BAFZの仮定 **ミニマックス最適**
Kim et al. (2021, Neural Networks)	誤判別率	ヒンジロス ロジスティックロス	BAFZの仮定 **ミニマックス最適**
Ohn & Kim (2022, Neural Computation)	**条件付き確率の推定** KL divergence	ロジスティックロス	BAFZの仮定 正則化有り
Bos & Schmidt-Hieber (2022, Electronic Journal of Statistics)	**条件付き確率の推定** 打ち切りKL divergence	負の対数尤度	一般的な仮定 KL より弱く, Hellingerより強い収束
Bildeau et al. (2023, Annals of Statistics)	**条件付き確率** KL divergence	負の対数尤度	MLEを変換した推定量
本研究 (2025+, Bernoulli)	**条件付き確率の推定** **Hellinger 距離**	**負の対数尤度**	**一般的な仮定** **ミニマックス最適** **証明の見通しが良い**

記号と仮定

⭐記号

- $H\left(P,Q\right)^2 := \frac{1}{2}\int\left(\sqrt{dP}-\sqrt{dQ}\right)^2$: 2つの分布間のHellinger距離の2乗
- $R(\boldsymbol{\eta}(\boldsymbol{X}),\boldsymbol{p}(\boldsymbol{X})) := \mathbb{E}_{\boldsymbol{X}}\left[H^2(\boldsymbol{\eta}(\boldsymbol{X}),\boldsymbol{p}(\boldsymbol{X}))\right]$
  - 本研究では，$\mathbb{E}_{\boldsymbol{X}}\left[\mathrm{KL}\left(\boldsymbol{\eta}(\boldsymbol{X})\parallel\hat{\boldsymbol{p}}(\boldsymbol{X})\right)\right]$ の代わりに$R(\boldsymbol{\eta}(\boldsymbol{X}),\hat{\boldsymbol{p}}(\boldsymbol{X}))$ の収束について議論する
  - $R(\boldsymbol{\eta}(\boldsymbol{X}),\hat{\boldsymbol{p}}_n(\boldsymbol{X})) \leq \mathbb{E}_{\boldsymbol{X}}\left[\mathrm{KL}\left(\boldsymbol{\eta}(\boldsymbol{X})\parallel\hat{\boldsymbol{p}}_n(\boldsymbol{X})\right)\right]$

⭐仮定

- $\exists\tilde{\boldsymbol{p}}_n\in\mathcal{F}_n,\ \exists c_0>0;\ \dfrac{\eta_k(\mathbf{x})}{\tilde{p}_{n,k}(\mathbf{x})}\leq c_0^2,\ \forall n\in\mathbb{N}, k=1,\ldots,K$
  - 深層学習を用いた推定では自動的に満たされる
  - 仮説空間のある元の台が真の条件付き確率の台を覆っている

オラクル不等式

⭐オラクル不等式

Theorem（オラクル不等式）

Kクラスの分類問題を考える.δ_n とある普遍定数 c は

$$\sqrt{n}\delta_n^2 \geq c\Psi(\delta_n)$$

を満たすとする．このとき，以下が成り立つ．

$$\mathbb{E}[R(\hat{\boldsymbol{p}}_n, \boldsymbol{\eta})] \leq 514(1+c_0^2)(\underbrace{\delta_n^2}_{\text{Variance}} + \underbrace{R(\tilde{\boldsymbol{p}}_n, \boldsymbol{\eta})}_{\text{Bias}^2}) + \frac{c^3}{n}$$

- Ψ は仮説空間の複雑さ，$R(\tilde{\boldsymbol{p}}_n, \boldsymbol{\eta})$ は推定量のバイアスを表している
- Tightなバウンドのためには $\tilde{\boldsymbol{p}}_n$ を $\boldsymbol{\eta}$ の近似列としてとる必要がある
- 仮説空間の複雑さとバイアスの評価ができればNPMLEの収束レートがわかる！
- 深層学習に限らず一般のNPMLEに対して成立

仮説空間の設定

⭐Deep Neural Network (DNN)

- $\sigma(x) := \max(0, x)$：活性化関数，$\mathbf{v} = (v_1, \ldots, v_r) \in \mathbb{R}$：バイアス
- $\sigma_{\mathbf{v}}(y_1, \ldots, y_r) = (\sigma(y_1 - v_1), \ldots, \sigma(y_r - v_r))$：バイアス込み活性化関数
- L：隠れ層の数，$\boldsymbol{m} = (m_0, \ldots, m_{L+1})$：各層の幅，
- $W_j \in \mathbb{R}^{m_{j+1} \times m_j}$：重み行列，$\boldsymbol{v}_i \in \mathbb{R}^{m_i}$：バイアスベクトル，
- $\boldsymbol{\Phi}$：ソフトマックス関数
- 順伝播型ニューラルネットワーク（FFNN）：

$$f : \mathbb{R}^{m_0} \to \mathbb{R}^{m_{L+1}},\ \boldsymbol{x} \mapsto f(\boldsymbol{x}) = \boldsymbol{\Phi} W_L \sigma_{\boldsymbol{v}_L} W_{L-1} \sigma_{\boldsymbol{v}_{L-1}} \cdots W_1 \sigma_{\mathbf{v}_1} W_0 \boldsymbol{x} \quad (\star)$$

- 層の深さL，層の幅m，パラメータの大きさの上界BのDNNの族

$$\mathcal{F}(L, \boldsymbol{m}, B) := \{f \text{ of the form } (\star) : \max_{j=0,\ldots,L} \|W_j\|_\infty \vee |\boldsymbol{v}_j|_\infty \leq B\}$$

真の条件付き確率の構造

⭐真の条件付き確率の構造

- 滑らかさ β, 定義域 D, ノルムの上限 Q のヘルダー空間：$\mathcal{C}^{\beta}(D, Q)$
- ヘルダー空間の元の合成で書ける関数の集合：

$$\mathcal{G}_{\mathrm{comp}}(q, \mathbf{d}, \mathbf{t}, \boldsymbol{\beta}, Q) = \{f = \boldsymbol{g}_q \circ \cdots \circ \boldsymbol{g}_0 : \boldsymbol{g}_i = (g_{ij})_j : [a_i, b_i]^{d_i} \to [a_{i+1}, b_{i+1}]^{d_{i+1}},$$
$$g_{ij} \in \mathcal{C}^{\beta_i}([a_i, b_i]^{t_i}, Q), \text{for some} |a_i|, |b_i| \leq Q\}$$

- $f(\underline{x_1, x_2, x_3}) = g_1 \circ \boldsymbol{g}_0(x_1, x_2, x_3) = g_{11}(g_{01}(\underline{x_1, x_3}), g_{02}(\underline{x_1, x_2}))$
  - 3次元
  - 2次元
- **背後に低次元構造がある**

- $\eta_k \in \mathcal{G}_{\mathrm{comp}}(q, \boldsymbol{d}, \boldsymbol{t}, \boldsymbol{\beta}, Q), \quad k = 1, \ldots, K$ を仮定
- 各合成の過程で効いてくる次元が小さくなる場合 $(t_i \leq d_i)$ に，
  t_i 個の次元だけを本質的に考慮すれば良い ⇒ 次元の呪いを回避

深層学習における収束レート

⭐深層学習における収束レート

Theorem（深層学習における収束レート）

以下の条件を満たすDNNモデルの集合 $\mathcal{F}(L, \boldsymbol{m}, B)$ を考える．

$$\text{(i)}\ \ L \asymp \log(n), \quad \text{(ii)}\ \ \sqrt{n\phi_n} \asymp \min_{i=1,\ldots,L} m_i, \quad \text{(iii)}\ B \asymp \max_{i=0,\ldots,q} (n\phi_n)^{\frac{2(\beta_i+1)}{t_i}}.$$

このとき，$q, \boldsymbol{d}, \boldsymbol{t}, \boldsymbol{\beta}, Q, K$ のみに依存する定数 C が存在して，

$$\mathbb{E}[R(\hat{\boldsymbol{p}}_n, \boldsymbol{\eta})] \leq C\phi_n \log(n)^3$$

が十分大きい n に対して成り立つ．ここで，

$\beta_i^* = \beta_i \prod_{l=i+1}^{r} (\beta_l \wedge 1)$, $\phi_n = \max_{i=0,\ldots,r} n^{-\frac{\beta_i^*}{\beta_i^* + t_i}}$ である．

- log-factor を無視すると，収束レートは ϕ_n
- **収束レートは次元 d に依存していない（次元の呪いの回避）**
- 深層学習は背後の低次元構造を適切に捉えることができる

DNNモデルのスパース性

⭐DNN のスパース性について

- 深層学習を用いて汎化誤差解析では, DNN にスパース性を仮定している研究が多い
  - すなわち DNN の非ゼロのパラメータ s は少ないと仮定している
  - e.g. Suzuki (2019), Schmidt-Hieber (2020)
- なぜか？ ⇒ 汎化誤差は, 典型的に以下の形で上から評価できる

$$\frac{\text{“Complexity”}}{n} + \text{Bias}^2$$

- “Complexity”は例えば: covering number, bracketing number
- DNN の covering number の上界は非ゼロのパラメータの数に比例
- ⇒ 非ゼロのパラメータの数 s を制限することで速い収束レートを得る
- **本研究では, よりタイトな Bias の評価 (Kohler & Langer, 2021) を用いることでスパース性を課さずに速い収束レートを示した**

オラクル不等式の仮定についての補足

⭐オラクル不等式の仮定はかなり弱い

- 仮定：

$$\exists \tilde{\boldsymbol{p}}_n \in \mathcal{F}_n,\ \exists c_0 > 0;\ \frac{\eta_k(\mathbf{x})}{\tilde{p}_{n,k}(\mathbf{x})} \leq c_0^2,\ \forall n \in \mathbb{N}, k = 1, \ldots, K$$

- Bounded away from zeroであるような条件付き確率が**<u>1つでも</u>**仮説空間に入っていれば良い（真の条件付き確率に依らない）

⭐タイトな不等式を導くためには．．．

- オラクル不等式：

$$\mathbb{E}[R(\hat{\boldsymbol{p}}_n, \boldsymbol{\eta})] \leq 514(1 + c_0^2)(\delta_n^2 + R(\tilde{\boldsymbol{p}}_n, \boldsymbol{\eta})) + \frac{c^3}{n}$$

- 右辺を小さくするためにはバイアス $R(\tilde{\boldsymbol{p}}_n, \boldsymbol{\eta})$ も小さくする必要がある

  ⇨ $\boldsymbol{\eta}$ がbounded away from zeroでない場合，**<u>仮定を満たしつつ</u>** $\tilde{\boldsymbol{p}}_n$ も小さい値を取れる必要がある

- **深層学習のアーキテクチャではそれが可能！**

ミニマックス最適性

⭐ミニマックス最適性

Theorem（ミニマックス最適性）

X_j が $[0,1]^d$ 上の Lebesgue 測度に関する密度をもつ分布に従うとし，
その密度が有界であるとする．このとき, 任意の非負整数 r ,
任意の $\boldsymbol{\beta} \in \mathbb{R}^r$, 任意の i に対して, $t_i \leq \min(d_0, \ldots, d_{i-1})$ を満たす $\mathbf{d}, \mathbf{t}$
と任意の十分大きい $Q > 0$ に対して, ある正定数 c が存在して

$$\inf_{\hat{\boldsymbol{p}}_n} \sup_{\eta_k \in \mathcal{G}_{\mathrm{comp}}(q,\boldsymbol{d},\boldsymbol{t},\boldsymbol{\beta},Q),\ k=1,\ldots,K} \mathbb{E}\left[R\left(\hat{\boldsymbol{p}}_n, \boldsymbol{\eta}\right)\right] \geq c\phi_n.$$

が成り立つ．下限は全ての推定量についてとる．

- この定理から，前スライドで導出した収束レートは
  log-factor を除いてミニマックス最適
- **深層学習はこの設定においてこれ以上改善できない最適な性能を発揮**

深層学習の優位性

⭐wavelet推定量との比較

- ロジスティック回帰による二値分類を考える
- $f_0(\boldsymbol{x}) \coloneqq h(\boldsymbol{w}^\top \boldsymbol{x}),\ h \in \mathcal{C}^1([0,d], Q)$：真のロジット関数
- $\eta(\boldsymbol{x}) \coloneqq \mathbb{P}(Y=1 \mid \boldsymbol{X}=\boldsymbol{x}) = \frac{1}{1+e^{-f_0(\boldsymbol{x})}}$：真の条件付き確率
- この場合は推定対象は真のロジット関数
- Theorem 3 から深層学習の収束レートが, Theorem 4 in Schmidt-Hieber (2020) から, wavelet 推定量の収束レートの下界がわかる

	深層学習	**wavelet（下界）**
収束レート	$n^{-\frac{1}{2}}$	$n^{-\frac{2}{2+d}}$

*この設定においては深層学習の収束レートは $n^{-2/3}$ まで速くなる（付録参照）

- 深層学習は次元によらない収束レートだが, **wavelet は次元の呪いの影響を強くうける**

深層学習の優位性

⭐wavelet推定量との比較

	深層学習	wavelet (下界)
収束レート	$n^{-\frac{1}{2}}$	$n^{-\frac{2}{2+d}}$

- 深層学習は次元によらない収束レートだが, wavelet は次元の呪いの影響を強くうける
- $d \geq 6$ の状況において, wavelet の収束レートは $o_p(n^{-1/4})$ を満たさない ⇒ **DMLが適用できない**
- **深層学習を用いる動機と根拠を提供！**

⭐今回は真の条件付き確率が合成関数の構造をもつと仮定したが, bias の評価ができている関数クラスであれば任意に置き換え可能

- e.g. Besov 空間, 区分線形関数

まとめ

- ⭐**条件付き確率のノンパラメトリック最尤推定において，分散を評価するための汎用的なオラクル不等式を示した**
  - 一般の最尤推定量に対して成立
  - Hellinger距離に関する評価
  - Bounded away from zeroの仮定なしでも適用可能
- ⭐**オラクル不等式の応用として，深層学習を用いたロジスティック回帰の収束レートを導出した**
  - DNNのスパース性を仮定しない
- ⭐**導出した収束レートのミニマックス最適性を示した**
  - 本研究の設定において深層学習はこれ以上改善できない最適な性能を発揮する

付録

セミパラメトリック推定への応用

⭐Double/Debiased Machine Learning (DML) との関係

- 因果推論の文脈において, 傾向スコア（＝共変量を条件付けたときの割り付けの**条件付き確率**）は因果効果を推定する際の局外母数として重要な役割を果たす
- 局外母数が非常に複雑な場合は, 機械学習 (ML) の方法を用いることで自然な推定量を与えることができる
- しかし, MLを用いたことによる bias や overfitting は推定量に悪影響を与える
  - 収束が遅くなる（$n^{-1/2}$-一致性が成り立たない）

⇒ DML (Chernozhukov et al., 2018) でこの問題を解決！

- Neyman-orthogonal moments / scores
- data-splitting の亜種 cross-fitting

セミパラメトリック推定への応用

⭐IPW推定量とELW推定量

- 欠測データ問題を考える
- X：共変量, Y：応答変数, D：Y の欠測の有無（0なら欠測）
- 観測データ $\{(D_i, D_iY_i, X_i)\}_{i=1}^N$ から $\mathbb{E}[Y]$ を推定したい
- 傾向スコア $\pi(X) = \mathbb{P}(D = 1 \mid X)$ が推定できれば,,,

$$\hat{\theta}_{\mathrm{IPW}} = \frac{1}{N} \sum_{i=1}^{N} \frac{D_i Y_i}{\pi(X_i)}$$

として推定できる！（Inverse Probability Weighting (IPW) 推定量）

- **しかし, 傾向スコアがゼロに近いと非常に不安定**

Q. 傾向スコアを深層学習で推定して問題ないのか？

セミパラメトリック推定への応用

⭐IPW推定量とELW推定量

Q. 傾向スコアを深層学習で推定して問題ないのか？

- 実際に深層学習では確率がゼロに推定されることがよくある

⇒ Empirical Likelihood Weighting (ELW) 推定量を用いればOK!

$$\hat{p}_i = \frac{1}{n} \frac{D_i}{1 + \lambda(\hat{\alpha})(\pi(X_i) - \hat{\alpha})}, \quad \hat{\theta}_{\mathrm{ELW}} = \sum_{i=1}^{N} \hat{p}_i Y_i$$

- 実際, 分母 $1 + \lambda(\hat{\alpha})(\pi(X_i) - \hat{\alpha})$ はゼロにならない
- 詳細は Liu & Fan (2023, JRSS B) を参照
- **ELW推定量とDMLを組み合わせることで, 傾向スコアが複雑な場合も深層学習を用いた強力な推定量を構成できる！**

深層学習における収束レート

⭐強い仮定を置くことによる収束レートの改善

- 真の条件付き確率が

$$0 < \exists c, C < 1;\ c < \eta_k < C, k = 1, \ldots, K$$

- を満たすなら, 深層学習の収束レートは $\max_{i=0,\ldots,r} n^{-2\beta_i^*/(2\beta_i^*+t_i)}$ まで改善できる
- しかし, 共変量が与えられたときに, 確実にクラスが分かるケースが存在しないことを仮定している

ミニマックス最適性

⭐ミニマックス最適性に関する補足

- 本研究で示したミニマックス下界はデータ数に関するもの
- Bilodeau et al. (2023) で示されたHölderクラスに対するミニマックスレートは $K^{\frac{2d}{d+\beta}} n^{-\frac{1}{d+\beta}}$
- 一方で，本研究でHölderクラスになる特殊ケースを考えるとミニマックス下限は $K^{-1} n^{-\frac{1}{d+\beta}}$
- **クラス数に関するミニマックス下限を示していない**
  - 深層学習もクラス数に関してミニマックス最適性を示せていない
- **本研究ではクラス数は定数として固定して考えたのでこれ以上詳細な解析は行わなかったが，Bilodeau et al. (2023) の方法を使えばクラス数に関してミニマックス下限が改善できる可能性がある**